

AI 错误冲击与重复人机决策中的动态依赖：一项基于 EWA 的实验研究

思考记录

标题

AI Error Shocks and Dynamic Reliance in Repeated Human-AI Decision Tasks: An EWA-Inspired Experimental Study

EWA 理论定位修正：从错误惩罚到动态依赖校准

AI 错误冲击与重复人机决策中的动态依赖：一项基于 EWA 的实验研究

摘要

随着生成式人工智能进入预测、判断与辅助决策场景，人类面对 AI 的问题已经不只是是否信任某一次输出，而是如何在重复反馈中学习何时依赖 AI、何时回到自我判断，以及何时改变人机分工方式。既有 algorithm aversion、trust in automation 与 AI-assisted decision-making 文献大多关注单轮建议采纳、局部信任校准或短期错误反应，较少考察在多轮反馈中，AI 的局部错误冲击如何改变人类后续对 AI 的依赖路径、恢复过程与决策架构偏好。

本研究提出，在重复人机决策任务中，AI 在某一阶段发生的局部错误冲击可能改变参与者后续对 AI 的依赖路径，并使其转向更强的 self-reliance。换言之，人类学习的并不只是 AI 是否在某一轮表现更好，而是在 repeated feedback 中不断比较 AI-generated allocation 与 self-generated allocation 的相对收益，并据此调整后续依赖。

为检验这一问题，本文设计一项 **AI 辅助的抽象动态多通道分配任务**。参与者每轮面对三个抽象通道： α 、 β 、 γ 。三个通道的回报由有噪声的动态过程生成，受到短期趋势、状态变化、均值回归和随机扰动共同影响。参与者需要根据历史信息将 100 点资源分配到三个通道中。随后，系统显示 Agent-AI 的建议分配方案，参与者需要在自己的方案和 AI 的方案之间选择最终提交。

实验的关键在于：每轮结束后，系统同时展示 self 方案和 AI 方案的反事实收益。也就是说，即使参与者没有采用 AI，也可以看到 AI 本轮如果被采用会获得多少收益；即使参与者采用了 AI，也可以看到自己的方案本来会获得多少收益。这个 full-feedback 设计使研究者能够观察参与者是否真的根据 AI 与 self 的相对表现更新依赖，而不是因为没有看到另一方表现而产生信息缺失。

实验采用 between-subjects 设计，核心处理是 AI error shock 的时间结构。Shock 条件中，AI 在预注册阶段出现数次集中明显错误，随后表现恢复；Balanced Error 条件中，AI 的错误次数、错误严重程度和总体收益与 Shock 条件相近，但错误以更平稳或分散的方式出现。若 Shock 条件在后续轮次中持续降低 AI 采用，则该结果不能简单解释为 AI 客观能力较差，而应被理解为局部错误冲击对后续 AI reliance 的路径性影响。扩展版本还可以进一步区分 Early Shock 与 Mid Shock，以比较初始校准冲击和已形成依赖关系被破坏之间的差异。

本文将 reduced-form 动态分析作为主证据，并使用 EWA-inspired attraction updating model 作为机制模型。Self 与 AI 被视为两个可选判断来源，每个来源具有随经验反馈更新的 attraction。EWA 模型用于检验 AI 错误是否比 self 错误更强地降低 AI 相关选择的吸引力，以及 AI 后续表现恢复是否足以修复错误冲击造成的吸引力下降。本文预期贡献在于，将 algorithm aversion 从单轮建议采纳问题推进为有限重复反馈环境中的动态依赖问题，并为 AI 在抽象动态分配任务中的依赖调整提供实验机制证据。

关键词：AI reliance; algorithm aversion; self-reliance; AI error shock; repeated human-AI decision-making; dynamic allocation task; EWA; human-AI decision-making; dynamic learning

一、引言

人工智能系统正在从信息工具转向预测、建议和辅助决策系统。在这些场景中，人类不只是判断 AI 的某一次输出是否可信，而是需要在重复互动中决定何时采用 AI、何时坚持自己的判断。AI 可以提供预测建议，也可以直接成为最终答案的来源。因此，人类对 AI 的学习对象并非单纯的准确率，而是 AI 相对于自我判断是否值得持续依赖。

既有研究已经说明，人类对算法错误并非完全理性或 source-neutral。Algorithm aversion 研究表明，人们在观察到算法犯错后，可能会过度回避算法，即使算法总体表现并不差。Trust in automation 和 appropriate reliance 文献则强调，问题不在于人是否盲目信任系统，而在于人是否能够形成适当依赖。然而，这些研究大多关注单轮建议采纳、短期信任变化或局部依赖校准，较少解释人类如何在多轮反馈中动态调整 AI reliance。

既有 human-AI decision-making 文献已经广泛讨论 algorithm aversion、algorithm appreciation、appropriate reliance 与 AI-assisted decision quality。然而，大多数研究仍然将 AI reliance 作为一次性或短期 advice-taking 结果来考察，或关注解释、信心、准确率提示等因素如何影响采纳。相对而言，较少研究将 AI advice 放入 repeated human-AI decision task 中，考察参与者如何在多轮反馈中根据 AI 与自我判断的相对表现动态校准依赖。尤其尚不清楚的是：当 AI 在互动过程中的某一阶段发生局部错误冲击、随后表现恢复时，参与者是否能够重新校准对 AI 的依赖，还是会持续回到自我判断，并因此错失 AI 的潜在决策收益。

本文的核心问题不是 AI 犯错后人类是否简单降低信任，而是人类如何在重复反馈中学习和校准 self-generated judgment 与 AI-generated judgment 的相对可靠性。在现实的人机协作中，个体面对的往往不是一次性 advice-taking，而是在多轮任务中反复比较“自己做”和“采用 AI”哪一个更值得依赖。因此，本文将 AI reliance 理解为一个动态校准过程：参与者根据每轮 self 与 AI 的反事实收益、错误大小和表现变化，不断调整后续对 AI 的采用。实验的最终目的，是为了揭示 AI 错误冲击如何改变后续依赖路径，并进一步检验 AI 错误与 self 错误在学习权重上的不对称性。

本文将这一机制放入一个 repeated decision game with feedback 中进行检验。参与者每轮面对一个抽象动态多通道分配任务，先形成自己的资源分配方案，再观察 AI 的分配建议，并在 self 与 AI 之间选择最终提交方式。每轮结束后，参与者根据 self 表现、AI 表现和反事实收益反馈更新对 self 与 AI 的主观吸引力，并在下一轮重新选择。该结构与 EWA，即 Experience-Weighted Attraction learning，的基本逻辑一致：策略选择并非一次性决定，而是在重复经验反馈中不断更新。

现实中的 AI 失败，很多时候不是模型平均性能不够，而是用户在互动中形成了错误的依赖路径；我们的实验就是要识别这种路径是如何形成、是否能够恢复，以及它会如何影响后续人机分工。

二、理论框架

2.1 从信任 AI 到在 self 与 AI 之间动态调整依赖

传统 AI 信任研究通常关心人类是否相信 AI、是否采纳 AI 建议，或是否根据 AI 置信度调整依赖程度。但在真实的人机协作环境中，人类面对的往往不是单次建议采纳问题，而是反复在自我判断与 AI 判断之间进行选择。

例如，在同一类预测任务中，个体可以选择：

1. 依靠自己的判断形成分配方案；
2. 参考 AI 建议但仍由自己决定；

3. 直接采用 AI 给出的分配方案。

在本文的实验中，为了降低选择复杂度并提高识别清晰度，本文将选择结构收缩为两个基本选项：采用自己的分配方案，或采用 AI 的分配方案。这样做的目的不是否认更复杂的人机协作架构，而是将研究焦点集中在最基础的问题上：当 self-generated allocation 与 AI-generated allocation 同时可见时，人类如何在重复反馈中调整对 AI 的依赖。

因此，本文的研究对象不是单次 trust，而是 **dynamic AI reliance**，即个体在多轮反馈中根据自身表现和 AI 表现不断调整是否采用 AI 的过程。

2.2 Self error 作为 human baseline

本文不将 external human advisor 放入主实验，而是将 self 作为 human baseline。这样处理的理论基础是：self error 也是 human error 的一种，但它不同于外部 human advisor error。

Self error 具有几个特殊心理含义。首先，自己的错误可能被理解为学习过程的一部分。其次，个体在自我判断中保留控制权，因此即使自己犯错，也可能不愿意立即转向 AI。第三，个体可能存在自我归因偏差或过度自信，从而对 self error 更宽容。

因此，本文的核心比较不是 AI error 与 external human advisor error，而是：

AI error versus self-generated error in repeated reliance decisions.

换言之，本文关注的问题是：当 AI 和自己都会犯错时，人们是否更容易原谅自己的错误，而更严厉地惩罚 AI 的错误？

这个设定更贴近日常 AI 使用场景。在现实中，很多 AI 辅助任务并不是让个体在 AI 和另一个人类专家之间选择，而是在“自己做”与“采用 AI”之间选择。因此，self vs AI 是研究 AI reliance 的一个基础场景。

2.3 为什么选择抽象动态多通道分配任务

本文采用 **抽象动态多通道分配任务** 作为基础实验环境。参与者面对的不是金融、医疗、招聘或市场预测等具体场景，而是三个抽象通道： α 、 β 、 γ 。每一轮，三个通道都会产生不同回报，参与者需要根据历史信息将 100 点资源分配到三个通道中。

选择这一任务的原因有三点。

第一，它足够抽象，能够避免现实场景标签带来的领域偏见。参与者不会因为任务被描述为金融预测、医疗诊断或招聘筛选而带入既有态度，从而使实验更集中地考察 self 与 AI 的动态依赖关系。

第二，它具有适度学习成本。通道回报由有噪声的动态过程生成，历史信息对下一轮有一定预测价值，但由于存在状态变化、均值回归和随机扰动，参与者无法在几轮之内完全掌握任务。这样可以避免任务变成纯随机猜测，也避免后期 AI 的作用因为任务过快被学会而消失。

第三，它能够自然产生 self 与 AI 的反事实收益。参与者每轮先提交自己的分配方案，再看到 AI 的分配建议，最后选择采用哪一个。任务结束后，系统可以同时计算 self 方案和 AI 方案在本轮真实通道回报下的收益。这使研究者能够直接观察参与者如何根据二者的相对表现调整后续依赖。

2.4 Repeated decision game with feedback

本文的实验并不需要被界定为标准两人 normal-form game。更准确的定义是：

a repeated decision game with feedback.

在每一轮中，参与者面对相同类型但参数和历史状态不断变化的动态分配任务。参与者先独立提交自己的资源分配方案，然后观察 AI advisor 的分配建议，并在 self 与 AI 之间选择最终提交方式。选择之后，参与者观察结果反馈，包括三个通道的真实回报、self 方案收益、AI 方案收益、实际收益与反事实收益。

因此，本文的核心学习对象不是某一轮具体分配给 α 、 β 、 γ 的点数，而是 self 与 AI 两种判断来源的 attraction。参与者在每一轮中都可以重新选择是否采用 AI，这使得 AI reliance 可以被观察为一个动态行为轨迹，而不是一次性采纳决定。

2.5 EWA 作为动态依赖校准模型

Experience-Weighted Attraction learning 的核心思想是，每个可选策略都有一个 attraction，该 attraction 会根据过去经验不断更新，并影响下一轮被选择的概率。本文将这一思想用于 self 与 AI 之间的依赖学习。

在本研究中，两个可选策略是：

1. **Self**：采用自己的分配方案；
2. **AI**：采用 AI advisor 的分配方案。

每轮动态分配任务都会产生 self 方案收益、AI 方案收益和反事实收益反馈。EWA-inspired model 则描述参与者如何将这这些反馈转化为对 self 与 AI 的 attraction 更新。与其将 EWA 仅仅用于检验 AI 错误是否被更强惩罚，本文更进一步将其作为一个动态依赖校准模型，用于解释 algorithm aversion、algorithm appreciation 与 appropriate reliance 如何在同一反馈学习过程中产生。

具体而言，如果 AI 错误导致 AI attraction 迅速下降，而后续 AI 正确反馈无法同等速度地恢复 AI attraction，则参与者可能表现出 algorithm aversion 或持续性 AI under-reliance。相反，如果 AI 成功反馈使 AI attraction 过度上升，或参与者对 AI 具有较高初始 attraction，则可能表现出 algorithm appreciation 或 AI over-reliance。若 self 与 AI 的 attraction 能够根据二者的相对表现及时更新，则参与者将表现出更接近 appropriate reliance 的动态校准。

因此，本文关注的不是 AI attraction 是否简单下降，而是 AI attraction 的更新是否具有来源特异性和方向不对称性。所谓来源特异性，是指 AI 错误与 self 错误可能引发不同的更新权重；所谓方向不对称性，是指 AI 的负向错误反馈与正向成功反馈可能具有不同的更新速度。本文尤其关注早期 AI 错误是否会造成 AI attraction 的过度下降，以及这种下降是否在后续 AI 表现恢复后仍然难以被完全修正。

这种框架与传统 algorithm aversion 研究有所不同。传统 algorithm aversion 通常关注个体在观察算法错误后是否降低算法使用，而本文关注在 repeated feedback 中，个体如何持续更新 AI 与 self 两种决策来源的相对吸引力。由此，algorithm aversion 和 algorithm appreciation 不再被视为两个相互割裂的现象，而是同一动态 attraction updating 过程在不同反馈历史和更新权重下的不同结果。

本文的核心结构命题因此可以表述为：AI advice 对人类决策的影响取决于参与者能否根据 self 与 AI 的相对表现动态校准二者的 attraction。早期 AI 错误可能作为 calibration shock，导致 AI attraction 的负向更新过强、正向恢复不足，进而造成后续 AI under-reliance 和潜在决策收益损失。

三、研究问题与假设

本文的总研究问题是：

在重复人机决策任务中，参与者如何根据 self 与 AI 的相对表现动态校准依赖？当 AI 在某一阶段发生局部错误冲击时，这种依赖路径如何改变？

因此，本文不把 AI 错误仅仅理解为一次性信任下降的诱因，而是将其视为 repeated feedback 中的 **calibration shock**。参与者在每一轮都能同时观察 self 与 AI 的反事实收益，由此可以持续比较二者的相对可靠性。实验真正关注的是：人在经历 AI 错误、AI 恢复、自我错误和自我成功之后，是否能够重新校准 self 与 AI 的相对吸引力，还是会形成持续性的 self-reliance 或 AI under-reliance。

具体而言，本文关注五个子问题：

1. 在多轮反馈中，参与者是否会根据 self 与 AI 的相对收益动态调整 AI reliance？
2. 当 AI 在某一阶段出现集中错误冲击后，参与者是否会降低后续 AI 采用？

3. 当 AI 后续表现恢复后，参与者是否能够重新校准对 AI 的依赖，还是会继续保持低 AI reliance？
4. 错误冲击发生在早期与中期时，其影响是否不同？早期 shock 更可能影响初始校准，中期 shock 更可能破坏已经形成的依赖关系。
5. AI 错误与 self 错误是否具有不同的学习权重，即参与者是否更严厉地惩罚 AI 错误，而更宽容地对待自己的错误？

3.2 研究假设

H1：动态依赖校准假设。

参与者在重复反馈中会根据 AI 与 self 的相对表现调整后续选择。当 AI 的反事实收益持续高于 self 时，AI 采用率应上升；当 AI 的反事实收益低于 self 时，AI 采用率应下降。

H2：AI error shock 惩罚假设。

相较于错误分散出现的 Balanced Error 条件，AI 错误集中出现的 Shock 条件将在冲击发生后表现出更低的 AI 采用率。这里的 shock 不必限定在早期，也可以发生在中期或其他预注册阶段。

H3：Post-shock recovery 与持续性低依赖假设。

如果参与者能够充分根据后续表现重新校准依赖，那么 AI 表现恢复后，Shock 条件下的 AI 采用率应逐步回升；如果存在路径依赖或信任滞后，则即使 AI 后续表现恢复，Shock 条件下的 AI 采用率仍将低于 Balanced Error 条件。

H4：Shock timing 异质性假设。

AI 错误冲击的影响取决于其发生时间。早期 shock 主要影响参与者对 AI 的初始可靠性判断；中期 shock 则发生在参与者已经积累一定 AI 使用经验之后，更可能表现为对既有依赖关系的破坏。因此，early shock 与 mid shock 可能通过不同机制影响后续 AI reliance。

H5：AI error 与 self error 的非对称学习假设。

AI 错误对后续 AI 采用的负向影响大于 self 错误对后续 self 采用的负向影响。换言之，参与者可能更容易将自己的错误归因为学习过程或任务噪声，而更容易将 AI 错误归因为系统可靠性不足。

H6：决策架构偏好转移假设。

AI error shock 不仅会影响每轮是否采用 AI，也会影响参与者对未来决策架构的偏好。经历 AI 错误冲击后，参与者更可能偏好 self-only 或 AI-assisted，而较少偏好 AI-delegated。

4. 实验设计

实验设计必须具备几个关键条件：

第一，需要多轮，研究的是动态依赖，不是一次性采纳。没有多轮，就无法观察错误后的下降、恢复、路径依赖和 EWA-style updating。

第二，需要一定学习成本，不能重复性过高，任务不能几轮就被学会，否则后期 AI 是否有用会消失。最好每轮结构一致，但参数、对手行为或信息环境变化。

第三，难度不能过高，过高会导致参与者直接全权委托给 AI，形成认知放弃。

第四，需要真正能够使用 AI，并且 AI 在实验过程中是能体现 AI 特点，能与普通机器学习算法区别开的。抑或是说，能让受试者真的觉得需要 AI，哪怕欺骗。

第五，需要足够干净，针对单个受试者。也就是每个受试者面对标准化环境，opponent agent 是为了控制对手行为、胜率、难度和 AI 错误时序，不是为了研究“人类和 AI 对手博弈”。

第六，需要有 self 与 AI 的反事实收益

第七，需要足够抽象，最好不涉及到具体的场景，为了保证足够的外部性。

实验设计

本研究采用一项 **AI 辅助的抽象动态多通道分配任务**。实验环境完全去除现实世界标签，参与者面对的不是金融、医疗、招聘或市场预测等具体场景，而是三个抽象通道： (α) 、 (β) 、 (γ) 。每一轮，三个通道都会产生不同的回报值，参与者需要根据历史信息将 100 点资源分配到三个通道中，并在自己的分配方案与 Agent-AI 的建议方案之间选择最终提交。

该任务的核心特点是：通道回报不是完全随机生成的，而是由一个有噪声的动态过程决定。每个通道的回报会受到短期趋势、状态转换、均值回归和随机扰动的共同影响。因此，历史信息对下一轮结果具有一定预测价值，但参与者无法通过简单重复策略完全掌握任务。这样可以保证任务既不是纯随机猜测，也不会在几轮之后被完全学会。

1. 任务环境

每一轮 (t) ，三个通道分别产生一个实际回报：

[

$V_{\alpha,t}, V_{\beta,t}, V_{\gamma,t}$

]

这些回报由后台预设的动态过程生成。参与者不会看到具体生成公式，只会看到三个通道过去若干轮的历史值。例如，屏幕上会显示最近 5 轮的通道表现：

[

```
\begin{array}{c|ccccc}
& t-5 & t-4 & t-3 & t-2 & t-1 \\
\hline
\alpha & 42 & 47 & 53 & 57 & 61 \\
\beta & 75 & 72 & 68 & 63 & 59 \\
\gamma & 31 & 38 & 44 & 49 & 55 \\
\end{array}
```

]

参与者需要根据这些历史变化判断下一轮哪些通道可能产生更高回报。为了避免参与者认为任务是完全随机的，实验说明中会明确告知：通道数值由动态规则生成，过去表现对未来有一定预测价值，但由于存在噪声和状态变化，预测不可能完全准确。

2. 参与者的自主分配

每一轮，参与者拥有 100 点资源，需要在三个通道之间进行分配：

[

$$a_{\{\alpha,t\}^{\{\text{Self}\}}} + a_{\{\beta,t\}^{\{\text{Self}\}}} + a_{\{\gamma,t\}^{\{\text{Self}\}}} = 100$$

]

例如，参与者可以提交：

[

$$\alpha=30, \beta=20, \gamma=50$$

]

该方案记为参与者的 self allocation。为了避免极端 all-in 策略，可以设置单一通道最高分配上限，例如每个通道最多分配 70 点。这样参与者需要判断三个通道的相对回报，而不是只猜一个最高通道。

3. Agent-AI 的建议

参与者完成自己的分配后，系统显示 Agent-AI 的建议方案。Agent-AI 被描述为一个基于大量历史序列训练的预测模型，它会根据三个通道的历史变化、近期趋势和波动模式，估计下一轮各通道的相对回报，并给出分配建议。

例如：

```
[  
\begin{array}{c|ccc}  
& \alpha & \beta & \gamma & \\ \hline  
AI\ 预估回报 & 62 & 48 & 76 & \\  
AI\ 建议分配 & 25 & 10 & 65 & \\  
\end{array}  
]
```

屏幕可以同时显示一个简单的 AI confidence，例如：

```
[  
AI\ confidence = 74%  
]
```

第一版实验不展示复杂解释矩阵或技术性公式。原因是复杂解释可能引入额外混淆：参与者可能因为解释看起来专业或不专业而改变信任，而不是因为 AI 的实际表现改变信任。因此，AI 的特征主要通过其任务功能体现：它基于历史动态模式进行预测，并给出可直接采用的分配方案。

4. 最终选择

在看到 Agent-AI 的建议后，参与者需要在两个方案中选择最终提交：

1. 采用自己的分配方案；
2. 采用 Agent-AI 的分配方案。

第一版实验采用二选一设计，而不允许参与者手动混合 self 与 AI。这样可以保证主要因变量更加清晰：参与者每轮是否选择依赖 AI。

```
[  
AdoptAI_{i,t} =  
\begin{cases}
```

```

1, & \text{if participant chooses AI allocation} \
0, & \text{if participant chooses self allocation} \
\end{cases}
]

```

5. 收益计算与反事实反馈

每轮结束后，系统公布三个通道的实际回报，并分别计算 self 方案和 AI 方案的收益。

如果某一方案的分配为：

```

[
a_{\alpha,t}, a_{\beta,t}, a_{\gamma,t}
]

```

本轮实际通道回报为：

```

[
V_{\alpha,t}, V_{\beta,t}, V_{\gamma,t}
]

```

则该方案收益为：

```

[
Payoff_t=
\frac{
a_{\alpha,t}V_{\alpha,t}
\cdot
a_{\beta,t}V_{\beta,t}
\cdot
a_{\gamma,t}V_{\gamma,t}
}{100}
]

```

每轮反馈界面必须展示完整反事实信息：

本轮实际通道回报：

$\alpha = 80, \beta = 20, \gamma = 40$

如果采用您的分配，本轮收益 = 54

如果采用 Agent-AI 分配，本轮收益 = 32

您实际采用：自己的分配

您的实际收益：54

这个 full-feedback 设计是实验的关键。即使参与者没有采用 AI，也可以看到 AI 本轮如果被采用会获得多少收益；即使参与者采用了 AI，也可以看到自己的方案本来会获得多少收益。这样才能观察参与者是否在看到 AI 后续恢复后仍然持续低依赖 AI。

6. 实验流程

实验分为三个阶段。

第一阶段是练习阶段。参与者先完成 3-5 轮无 AI 的练习任务，以理解通道回报并非完全随机，历史信息具有一定预测价值，但任务也无法被简单掌握。

第二阶段是正式任务。正式任务建议设置为 30 轮，分为 6 个 block，每个 block 包含 5 轮。每一轮流程固定为：

1. 显示三个通道最近几轮历史值；
2. 参与者提交自己的分配方案；
3. 显示 Agent-AI 的分配建议；
4. 参与者选择采用 self 或 AI；
5. 公布三个通道实际回报；
6. 公布 self 收益、AI 收益和实际收益；
7. 进入下一轮。

第三阶段是 block-level 测量。每 5 轮结束后，系统询问参与者下一阶段更偏好的决策架构：

1. Self-only：只依赖自己，不使用 AI；
2. AI-assisted：先自己判断，再参考 AI，最后自己决定；
3. AI-delegated：直接采用 AI 建议。

第一版实验中，该问题可以先作为偏好测量，而不一定真的改变下一 block 的界面。这样可以避免不同架构导致信息暴露不一致，同时仍然能够测量 AI 错误是否改变参与者偏好的决策架构。

7. 实验处理条件

实验的核心处理不是“AI 是否会犯错”，而是 **AI 错误冲击的时间结构**。所有条件下，Agent-AI 的总体表现都应保持相近；不同条件的关键差异在于错误是否集中出现，以及集中出现的位置。

条件一：AI Error Shock

Agent-AI 在某一预注册阶段集中出现几次明显错误，但后续逐渐恢复，并且整个实验中总体表现仍然较好。Shock 可以设置在早期 block，也可以设置在中期 block。早期 shock 更像是初始校准冲击，中期 shock 更像是对已形成依赖关系的破坏。

条件二：Balanced AI Error

Agent-AI 的错误次数、错误严重程度、总体收益与 Shock 条件保持一致，但错误分散出现在整个实验过程中，而不是集中发生在某一阶段。

如果样本量允许，实验可以进一步扩展为三个条件：

Early Shock：错误集中发生在早期 block；
Mid Shock：错误集中发生在中期 block；
Balanced Error：错误分散发生，作为基准路径。

各条件需要保持一致的部分包括：

AI 总收益；
AI 平均收益；
AI 错误次数；
AI 大错误次数；
AI 后续表现；
通道真实回报序列；
参与者看到的历史信息。

条件之间的核心差异是：

AI 错误是否集中发生；
如果集中发生，错误冲击发生在早期还是中期。

8. AI 错误的控制

AI 错误不应完全依据参与者自己的表现来定义，因为不同参与者的 self 分配不同。如果用 “AI 收益低于 self 收益” 作为处理操控标准，那么 AI 是否错误会因人而异，无法被实验者完全控制。

因此，AI 错误时序应基于外部 benchmark 预先设定。例如可以使用：

1. 平均分配 benchmark；
2. 简单启发式 benchmark，例如更多分配给上一轮最高通道；
3. pilot-human benchmark，即预实验中普通参与者的平均方案；
4. hindsight optimal benchmark，即基于真实回报的最优方案。

主处理可以定义为：

```
[  
Loss^{AI}_t = Payoff^{Benchmark}_t - Payoff^{AI}_t  
]
```

正式分析中，再使用个体层面的：

```
[  
Payoff^{AI}_t - Payoff^{Self}_t  
]
```

来观察参与者如何根据 AI 与 self 的实际相对表现更新依赖。

9. 主要记录变量

实验过程中记录以下变量：

```
每轮 self 分配方案；  
每轮 AI 分配方案；  
每轮最终采用来源；  
self 方案收益；  
AI 方案收益；  
实际收益；  
AI 是否在该轮相对失败；  
AI 错误大小；  
AI 错误发生时间；  
每个 block 后的 AI 信任评价；  
每个 block 后的决策架构偏好。
```

实验后还需要测量参与者对任务和 AI 的理解，包括：

参与者是否认为任务完全随机；
参与者是否认为历史信息有用；
参与者是否认为 AI 总体有用；
参与者是否注意到 AI 错误冲击；
参与者是否认为 AI 后续表现恢复；
参与者如何归因 AI 错误；
参与者如何归因自己的错误。

其中，“任务是否被认为完全随机”是关键检查项。如果大量参与者认为任务只是随机数生成，那么 AI advisor 的存在就失去合理基础，实验设计需要重新调整。

10. 设计总结

该实验通过一个抽象动态分配任务，在去除现实标签的同时保留 AI 辅助决策的核心结构。参与者面对的是一个有噪声但可学习的动态环境，需要在 self judgment 和 Agent-AI advice 之间反复选择。每轮 full-feedback 同时提供 self 与 AI 的反事实收益，使研究者能够观察 AI 错误冲击后依赖是否下降、AI 表现恢复后依赖是否恢复，以及参与者是否改变对 self-only、AI-assisted 和 AI-delegated 等决策架构的偏好。

该设计的关键不在于模拟某个具体应用场景，而在于构造一个干净、可控、可多轮、AI 确实有用且每轮存在反事实收益的实验环境。

11. 分析模型设计与参数细节

本研究的分析策略分为三层：第一层是 reduced-form 动态路径分析，用于识别 AI error shock 是否改变后续 AI 采用；第二层是 event-study 式的恢复轨迹分析，用于观察 shock 之后 AI reliance 是否恢复；第三层是 EWA-inspired 机制模型，用于解释参与者如何根据 self 与 AI 的相对表现更新二者的吸引力。

11.1 数据结构与核心变量

实验数据为 participant-round panel。设参与者为 i ，轮次为 t ，block 为 b 。每位参与者完成 30 轮正式任务，每 5 轮构成一个 block。

核心因变量为每轮是否采用 AI：

$\text{AdoptAI}_{it} = 1$ 表示参与者 i 在第 t 轮采用 AI 分配方案； $\text{AdoptAI}_{it} = 0$ 表示采用自己的分配方案。

核心解释变量包括：

1. Shock_i ：参与者是否处于 AI 错误集中冲击条件；

2. ShockTiming_i：错误冲击发生的位置，例如 Early Shock 或 Mid Shock；
3. PostShock_{it}：第 t 轮是否处于该参与者经历 shock 之后；
4. Recovery_{it}：第 t 轮是否处于 AI 表现恢复阶段；
5. RelativePayoff_{i,t-1}：上一轮 AI 收益与 self 收益之差；
6. CumAdvantage_{i,t-1}：截至上一轮 AI 相对于 self 的累计收益优势；
7. Distance_{it}：本轮 AI 分配方案与 self 分配方案之间的距离；
8. AdoptAI_{i,t-1}：上一轮是否采用 AI，用于控制选择惯性。

其中，Distance_{it} 可以用三个通道分配差异的绝对值之和衡量。该变量用于控制一种重要替代解释：参与者不采用 AI 可能并不是因为不信任 AI，而是因为 AI 建议与自己的初始判断差异过大。

11.2 主模型：动态处理效应模型

主分析采用二元选择模型，解释每一轮是否采用 AI。核心思想是比较 Shock 条件与 Balanced Error 条件在 shock 之后的 AI 采用路径差异。

基本模型可以写成：

AdoptAI_{it} = f(Shock_i × PostShock_{it}, Shock_i × Recovery_{it}, RelativePayoff_{i,t-1}, CumAdvantage_{i,t-1}, Distance_{it}, AdoptAI_{i,t-1}, round fixed effects, individual controls)

其中，最关键的参数有两个：

1. Shock_i × PostShock_{it}：检验错误冲击后 AI 采用是否下降；
2. Shock_i × Recovery_{it}：检验 AI 表现恢复后，AI 采用是否仍然低于对照条件。

如果 Shock_i × PostShock_{it} 为负，说明 AI error shock 会导致后续 AI reliance 下降。如果 Shock_i × Recovery_{it} 仍然为负，说明即使 AI 后续表现恢复，参与者也没有完全重新校准对 AI 的依赖。

在展示中，这个模型不需要展开复杂公式。核心图应是两组或三组的 AI adoption trajectory：shock 前是否接近、shock 后是否分化、recovery 阶段是否重新收敛。

11.3 Shock timing 分析

如果实验设置 Early Shock、Mid Shock 和 Balanced Error 三个条件，则模型中进一步区分错误冲击发生时间：

1. Early Shock：错误集中发生在早期 block，主要检验初始校准是否被负面经验影响；

2. Mid Shock：错误集中发生在中期 block，主要检验已形成的 AI reliance 是否会被局部失败破坏；
3. Balanced Error：错误次数和严重程度相近，但分散出现，作为基准路径。

核心比较包括：

1. Early Shock vs Balanced Error：早期负面经验是否造成后续低依赖；
2. Mid Shock vs Balanced Error：已建立依赖后的错误冲击是否破坏后续采用；
3. Early Shock vs Mid Shock：初始印象冲击与依赖关系破坏是否具有不同影响。

理论上，Early Shock 可能通过 negative anchoring 影响初始 AI attraction；Mid Shock 则可能通过 expectation violation 破坏已经形成的依赖关系。因此，二者方向可能相同，但机制含义不同。

11.4 Event-study 式恢复轨迹分析

为了更直观地展示 shock 之后的依赖变化，本文将以 shock 发生轮次为事件时间 0，绘制 shock 前后 AI 采用率的动态路径。

事件时间可以定义为：

$$k = t - \text{shock_start}$$

其中 $k < 0$ 表示 shock 前， $k = 0$ 表示 shock 开始， $k > 0$ 表示 shock 后。分析重点包括：

1. shock 前两组 AI 采用率是否接近；
2. shock 发生后 AI 采用率是否立即下降；
3. shock 后 1-2 个 block 内是否出现恢复；
4. recovery 阶段是否仍然存在持续性低 AI reliance。

这部分的核心展示是一张 event-time 图。相比回归表，它更适合 10 分钟汇报，因为可以直接显示 AI reliance 的下降、恢复或滞后。

11.5 EWA-inspired 机制模型

EWA-inspired 模型用于解释参与者如何在重复反馈中更新 self 与 AI 的相对吸引力。本文不将 EWA 作为唯一主证据，而是将其作为机制模型。

基本设定是：参与者对 AI 和 self 分别有一个 attraction。每轮反馈之后，这两个 attraction 会根据收益表现、错误大小和反事实收益被更新。下一轮参与者是否采用 AI，取决于 AI attraction 相对于 self attraction 的大小。

模型包含以下关键参数：

1. 记忆保留参数 ρ ：表示过去经验在当前 attraction 中保留的程度。 ρ 越高，说明早期经验影响越持久。
2. AI 正向学习权重 λ_{AI+} ：表示 AI 表现优于 self 时，AI attraction 上升的幅度。
3. AI 负向学习权重 λ_{AI-} ：表示 AI 表现差于 self 或出现明显错误时，AI attraction 下降的幅度。
4. Self 正向学习权重 λ_{self+} ：表示 self 表现优于 AI 时，self attraction 上升的幅度。
5. Self 负向学习权重 λ_{self-} ：表示 self 表现差于 AI 时，self attraction 下降的幅度。
6. 选择敏感度 θ ：表示 attraction 差异对下一轮采用 AI 的影响强度。
7. 惯性参数 κ ：表示上一轮采用 AI 是否会提高下一轮继续采用 AI 的概率。
8. 距离惩罚参数 ψ ：表示 AI 建议与 self 初始判断差距越大时，参与者越不愿采用 AI。

本文最关键的机制检验不是估计所有参数本身，而是比较两个不对称性：

1. 来源不对称：AI 错误的负向学习权重是否大于 self 错误的负向学习权重，即 $\lambda_{AI-} > \lambda_{self-}$ ；
2. 方向不对称：AI 错误造成的下降是否大于 AI 后续成功带来的恢复，即 $\lambda_{AI-} > \lambda_{AI+}$ 。

如果这两个不对称性成立，则说明参与者并不是简单地根据收益理性切换，而是对 AI 错误具有更强的惩罚权重，并且 AI 后续恢复不足以完全修复早期或中期错误冲击造成的 attraction 下降。

11.6 三模型比较

本文将比较三个模型，以检验观察到的 AI reliance trajectory 更接近哪一种机制。

1. **Inertia-only model**：参与者主要根据上一轮选择继续行动，AI 采用路径主要由习惯或 switching cost 解释。
2. **Source-neutral learning model**：参与者对 AI 错误和 self 错误使用相同学习权重，只根据收益差异更新。
3. **EWA-inspired asymmetric learning model**：参与者对 AI 与 self 使用不同学习权重，并且对 AI 的负向反馈和正向反馈存在不对称更新。

如果 asymmetric learning model 比 source-neutral learning model 和 inertia-only model 更好地解释数据，并且 λ_{AI} 明显大于 λ_{self} ，则支持本文关于 AI error shock 与动态依赖校准的机制解释。

11.7 参数与实验实现建议

第一版实验建议采用 30 轮正式任务，分为 6 个 block，每个 block 5 轮。练习阶段为 3-5 轮，不进入主分析。

关键实验参数建议如下：

1. 总资源：每轮 100 点；
2. 通道数量：3 个，即 α 、 β 、 γ ；
3. 单通道分配上限：70 点，避免 all-in 策略；
4. 历史窗口：每轮展示最近 5 轮通道表现；
5. 正式轮次：30 轮；
6. Block 数量：6 个，每个 block 5 轮；
7. Shock 强度：在 shock block 中设置 3-4 次明显 AI 错误；
8. Balanced Error 条件：错误次数、错误严重程度和 AI 总收益与 Shock 条件匹配，但错误分散出现；
9. Recovery 阶段：shock 后 AI 表现恢复到较高水平，并保持总体上优于简单 benchmark；
10. 主因变量：每轮是否采用 AI；
11. 机制变量：AI 与 self 的收益差、累计收益差、方案距离、block-level 架构偏好与错误归因。

Pilot study 需要重点校准三个参数：任务难度、AI 总体有用性和 shock 显著性。理想状态是：参与者认为历史信息有用，但无法几轮内完全掌握任务；AI 总体表现优于平均分配或简单启发式 benchmark；shock 足够明显，但不至于让参与者认为 AI 被实验者故意操控。

三模型比较的思路

十、效度与替代解释10.1 内部有效性

本文的内部有效性依赖于 AI 表现控制和共同反馈设计。Shock 条件与 Balanced Error 条件在 AI 总体表现上尽可能接近，排除了“Shock 条件中的 AI 真的更差”的替代解释。每轮展示 self 与 AI 的方案收益和反事实收益，排除了参与者没有观察到 AI 后续表现的 exposure 内生性。

10.2 构念有效性

本文的核心构念是 dynamic AI reliance，而非单次 trust。为此，研究同时测量实际 AI 采用行为和个体对 AI 能力、自己能力以及错误归因的评价。如果参与者在 AI error shock 后降低 AI 采用，同时降低对 AI 作为判断来源的适配性评价，或改变对 self-only、AI-assisted、AI-delegated 的架构偏好，则更能支持动态依赖更新解释。

10.3 替代解释

第一，若结果来自一般风险厌恶或损失厌恶，则 self error 和 AI error 对后续选择应产生类似影响。

第二，若结果来自一般行为惯性，则 inertia-only model 应足以解释选择轨迹。

第三，若结果来自 anti-AI prior，则控制基线 AI 态度后处理效应应显著减弱。

第四，若结果来自 AI 客观表现较差，则 AI 总体表现控制将直接削弱该解释。

第五，若结果来自过度自信或控制偏好，则 self-confidence 和 control preference 应显著调节 AI error shock 的影响。

十一、预期贡献

11.1 理论贡献

本文将 algorithm aversion 从单轮建议采纳推进为有限重复反馈中的动态依赖问题。研究不只问人是否在一次错误后回避 AI，而是问 AI 错误冲击如何改变后续依赖路径、恢复过程和人机分工偏好。

11.2 方法贡献

本文提出一种将抽象动态多通道分配任务、repeated decision game with feedback、AI 错误时序控制和 EWA-inspired 模型结合的实验框架。该框架能够在不依赖复杂真实业务场景的情况下，研究重复人机决策环境中的 AI reliance updating。

11.3 任务设计贡献

本文将抽象动态分配任务设计为一个人机协作依赖实验的反馈环境。其价值不在于模拟某个具体应用领域，而在于提供一个足够抽象、可控且可参数化的任务结构，使研究者能够检验 AI 错误冲击如何影响后续 self 与 AI 之间的依赖选择。

11.4 AI 治理贡献

如果 AI 错误冲击在后续表现恢复的条件下仍导致持续性低采用，则说明 AI 部署过程中的错误时序具有特殊治理意义。组织不应只关注 AI 平均准确率，还应关注局部错误冲击如何改变后续 reliance trajectory、恢复机会和用户角色认知。

十二、external human advisor 的扩展位置

本文主实验不直接引入 external human advisor。原因是 external human advisor 会将选择结构从 Self vs AI 改变为 Self vs AI vs Human Advisor，从而显著增加实验复杂度、样本压力和 EWA 参数数量。

但是，external human advisor 可以作为后续研究或扩展模块。该扩展可用于回答：当参照对象不是 self，而是 external human advisor 时，AI early error 是否仍会导致相对低 AI reliance？

这一扩展可以被称为 reference-option extension，而不是主实验的异质性分析。它可以帮助区分：

1. AI under-reliance 是否只发生在 self 与 AI 的比较中；
2. AI under-reliance 是否也存在于 AI 与 external human advisor 的比较中；
3. 参与者在放弃 AI 后，是回到 self，还是转向另一个外部人类建议者。

因此，本文将 external human advisor 保留为理论延展方向，而不放入当前主实验。

十三、结论

本研究提出一项 repeated decision game with feedback，用以检验 AI 错误冲击是否会在重复人机决策任务中造成持续性低 AI reliance。实验采用抽象动态多通道分配任务作为反馈环境，将 self 与 AI 视为两个可选判断来源，并用 EWA-inspired model 描述参与者如何根据经验反馈更新不同来源的 attraction。

研究的核心识别原则是：Shock 条件与 Balanced Error 条件中的 AI 总体表现尽可能接近，实验主要操控错误是否集中出现，以及错误冲击发生在何种阶段。由此，若

Shock 条件在后续轮次中持续降低 AI 采用，则说明 AI 错误冲击可能引发路径依赖式的动态低依赖，而不是仅仅根据当前客观表现进行即时调整。

本文最终试图建立一条清晰机制链：

抽象动态分配任务 → self/AI 反事实收益反馈 → self 与 AI attraction 更新 → 后续 AI reliance 选择 → AI error shock 后的持续性低依赖与决策架构偏好转移。

参考文献

- Camerer, C. F., & Ho, T.-H. (1999). Experience-weighted attraction learning in normal form games. *Econometrica*, 67(4), 827–874.
- Erev, I., & Roth, A. E. (1998). Predicting how people play games: Reinforcement learning in experimental games with unique, mixed strategy equilibria. *American Economic Review*, 88(4), 848–881.
- Hyndman, K., Ozbay, E. Y., Schotter, A., & Ehrblatt, W. Z. (2012). Convergence: An experimental study. *Games and Economic Behavior*, 74(1), 207–222.
- Hyndman, K., Terracol, A., & Vaksman, J. (2009). Strategic interactions and belief formation: An experiment. *Experimental Economics*, 12, 398–423.
- Lee, J. D., & See, K. A. (2004). Trust in automation: Designing for appropriate reliance. *Human Factors*, 46(1), 50–80.
- Dietvorst, B. J., Simmons, J. P., & Massey, C. (2015). Algorithm aversion: People erroneously avoid algorithms after seeing them err. *Journal of Experimental Psychology: General*, 144(1), 114–126.
- Logg, J. M., Minson, J. A., & Moore, D. A. (2019). Algorithm appreciation: People prefer algorithmic to human judgment. *Organizational Behavior and Human Decision Processes*, 151, 90–103.
- Parasuraman, R., Sheridan, T. B., & Wickens, C. D. (2000). A model for types and levels of human interaction with automation. *IEEE Transactions on Systems, Man, and Cybernetics-Part A: Systems and Humans*, 30(3), 286–297.
-

问题备忘录30 轮到底够不够？

30 轮能够覆盖 baseline、shock、adjustment 和 recovery 阶段，比 8–12 轮更适合观察动态依赖校准；但它仍然不应用来声称长期稳态。更稳妥的表述是：在有限重复窗口中的持续性 post-shock under-reliance。

抽象动态分配任务会不会太快被学会？

这是核心风险之一。任务必须保持同一结构，但每轮的参数、状态和噪声环境要发生变化。理想状态是：历史信息有一定预测价值，参与者能够学习到部分规律，但无法在几轮之内完全掌握任务。Pilot study 需要重点检验任务是否既不是纯随机，也不是过快收敛。

两组设计是否会损失理论广度？

两组设计牺牲了 AI vs external human advisor 的来源比较，但显著提高了实验清晰度、样本效率和模型可估计性。当前主问题应明确为 self vs AI，而不是 AI vs human advisor。

AI 表现控制能不能真的做到？

这是实验识别的命门。现在需要设计具体的 30 轮通道回报矩阵和 AI 分配矩阵，确保 Shock 条件与 Balanced Error 条件在平均收益、错误次数、错误严重程度和累计收益上尽可能接近。否则读者会怀疑处理效应来自 AI 总体表现差异。

EWA 会不会在 30 轮里估不稳？

这是方法上最大的风险。30 轮可以用 EWA-inspired model，但不要把它当强结构估计。主证据应该是 reduced-form 条件比较和动态路径图，EWA 只作为机制辅助，重点检验 AI 错误与 self 错误的学习权重是否不对称，不要估太多复杂参数。

反馈信息给得太多，会不会削弱路径依赖？

现在每轮显示 self/AI 的预测误差和反事实收益。好处是排除了“参与者没看到 AI 后续表现”的问题；坏处是路径依赖会更难出现，因为参与者有充分反事实信息。如果这种情况下仍出现 AI 低依赖，结果会很强；但效应可能更小。

是否还需要 external human advisor？

主实验不需要。external human advisor 可以作为后续扩展，用来检验 AI under-reliance 是否也存在于 AI 与外部人类建议者之间的比较中。当前不建议把它放进主实验，否则会重新回到复杂设计。

需要记录的问题

修改后的实验