责任归因

理论背景

- AI委托研究。Xu et al.（2026）考察困难权衡是否提高AI委托意愿；Köbis et al.（2025）表明，机器委托的接口和AI的执行方式能够改变不道德行为。这些研究说明，委托可能改变决策行为，也可能改变事后的责任评价，但研究结果集中在不诚实行为及其实施成本，没有考察群体冲突，也没有比较不同利益位置的人如何理解责任。
- 第二类是AI责任归因研究。Shank et al.（2019）、Awad et al.（2020）、Dong and Bocian（2024）等研究考察AI参与后，观察者如何在人类和AI之间分配责任。这些研究的结果并不一致：AI参与有时降低人类责任，有时没有降低，有时还会使责任重新回到拥有控制权或选择使用AI的人类。

理论背景： AI参与后，责任并不沿着一个固定方向移动

- 第一，AI有时获得更多责任。AI被描述为更自主、更有行动能力，或者更像具有意图的行动者时，观察者可能增加对AI的责备。
- 第二，人类或组织有时获得较少责任。Shank等人（2019）发现，人类监督AI时受到的道德过错评价低于人类独立决策，但AI受到的过错评价没有同步增加。Bigman等人（2023）发现，算法歧视引发的道德愤怒和组织追责较低，其中一个解释是人们较少向算法归因偏见动机。
- 第三，AI参与也可能提高人类责任。Arnestad等人（2024）发现，只要存在手动接管选项，人类就会受到更多责备，即使其实际上没有足够时间或能力进行干预。Alon-Barkat等人（2025）也发现，算法标签本身并不会稳定降低组织责任；外部供应商和组织对结果的感知影响力更关键。

AI责任上升、人类责任下降和人类责任上升，分别受到不同判断规则影响。不能将它们统一概括为“责任向AI转移”。而在高冲突场景，这样的责任转移研究仍然是空白

责任判断会受到评价者利益位置的影响

- Dong和Bocian（2024）提供了最接近当前研究的证据。在相同的人机共同违规情境下，人们评价自己或内群体成员时更加宽松，而且更愿意把责任归给AI；评价他人或外群体成员时，这种责任分配方式减弱。

如果是两个存在真实利益冲突的群体呢？责任的判断会怎么改变？

如果责任判断受到利益和群体立场影响，受益方成员、受损的方成员和决策者将形成不同的责任分配。

总结

- AI委托可能改变人的行为；
- AI参与可能改变人类、AI和组织之间的责任分配；
- 评价者的自我利益或群体身份可能影响责任判断。
- 但缺少对这三个过程的联合检验。尤其缺少这样一种研究结构：

联合结构具有三层意义：
现实意义：保留从授权到结果再到追责的完整时间顺序。
识别意义：将人类主动委托、AI作出的选择和事后归责连接起来，避免把AI委托当成外生背景。
理论意义：检验相同的责任结构是否会因为受益、受损和自我评价位置不同而产生不同解释，并进一步区分责任判断与实际处罚。

现实中的AI冲突决策通常按照以下
发生：
人类决定是否交出最终决定权
→ 人或AI作出升级选择
→ 冲突产生受益方和受损方
→ 各方解释人类与AI的责任
→ 组织内部决定是否处罚原决策者

在群体利益冲突中，AI 是否会改变决策的升级选择，以及选择后果的责任归因？

- 主研究问题：
- 在群体利益冲突中，AI 是否会改变决策的升级选择，以及选择后果的责任归因？

三个子问题

RQ1：行为。 在高冲突情境下，迫于冲突与道德压力，人类是否更愿意把冲突决策委托给 AI 而非自己作出决策？

RQ3：归责。 对完全相同的冲突结果，不同群体成员如何分配人类决策者与 AI 的因果责任和道德责备？

**RQ3：在高冲突情境下，AI 委托是否改变最终升级结果？

本文拟检验的完整过程

- AI 委托选项是否可用
- ↓
- 处理组决策者选择自行决策或委托给 AI
- ↓
- 人类或 AI 的最终选择改变两个群体的真实收益
- ↓
- 受益方成员 / 受损方成员 / 决策者观察同一决策记录
- ↓
- 三类评价者分别判断因果责任与道德责备

. **AI委托与冲突行为*：AI 委托选项是否改变谁作出最终选择以及最终升级率；
2. **利益位置与责任归因**：受益方和受损方是否对同一决策记录作出不同归责；
3. **自我归责与外部归责**：决策者是否以不同于受益方和受损方成员的方式分配人类与 AI 的责任

群体设计的重要性

- Social preference理论认为，个体的选择会受到以下因素影响：
- 收益分配：个体关心自身与他人的收益差距
- 自身利益：受益或受损可能影响人们如何在人类与AI之间分配责任
- Self-interest bias；Dong & Bocian, 2024
- 群体设计将AI委托从个人风险选择，推进为影响真实他人收益的社会决策。
  这是在前置研究实验中没有做到的

同时，决策者同时面对保护本方利益和避免伤害对方的冲突。
群体关系可能改变决策者赋予本方与对方收益的权重。
Group-contingent social preferences

- 更接近现实冲突的基本结构
- 现实中的组织冲突、劳资冲突、平台治理和国家间冲突通常具有以下特征：
- 现实冲突　　实验对应
- 少数人代表群体作出决定　　设置拥有决定权的群体决策者
- 决策后果由多人共同承担　　本方和对方成员获得真实收益或损失
- 决策者可能将部分决定权交给AI　　决策者选择亲自决策或委托AI
- 冲突产生受益方和受损方　　实验结果形成真实利益位置
- 不同利益相关者事后解释责任　双方评价人类决策者与AI的责任

激励行为实验**：参与者的选择、委托或惩罚直接影响本人或他人的实验收益；

- 使用鹰鸽博弈，

