

算法权威与双重贝叶斯偏离：生成式 AI 如何重塑不确定性下的证据抽样与信念更新

时间 6月10号左右，周，张老师

算法权威与双重贝叶斯偏离：生成式 AI 如何重塑不确定性下的证据抽样与信念更新

一、引言与研究背景

生成式人工智能的迅速扩散正在改变人类在不确定性环境中获取信息、组织证据和形成判断的基本方式。与搜索引擎、数据库和传统推荐系统不同，生成式 AI 并不只是帮助用户更快地找到信息，也不只是向用户推荐某个选项。它越来越多地被用于解释疾病风险、投资前景、职业选择、公共政策、法律责任、历史争议和社会冲突等高度不确定的问题。在这些场景中，用户面对的往往不是一个已经存在明确答案的事实查询，而是一个证据不完整、来源异质、解释相互竞争、结论具有概率性的判断任务。

在传统信息环境中，个体通常需要先接触证据，再逐步形成解释和判断。即使搜索引擎和推荐系统降低了信息获取成本，用户仍然需要在多个来源之间比较证据、识别冲突、判断可靠性，并决定何时停止搜索。换言之，传统信息技术主要改变的是信息搜寻的效率和路径，而没有完全替代个体对证据空间的直接接触。用户虽然可能受到排序、推荐和注意力分配机制的影响，但他们通常仍然能够意识到自己面对的是一个由多个来源、多个观点和多个证据片段构成的信息环境。

生成式 AI 改变了这一认识论顺序。大语言模型通常不会首先向用户呈现一组分散的信息来源，而是直接生成一个结构化、连贯且看似充分综合的解释。用户因此往往在充分暴露于原始证据之前，就已经接触到一个被算法组织过的判断框架。这个框架不仅包含结论，也包含理由、证据排序、冲突处理和因果叙事。由此，用户面对的不是未经加工的证据环境，而是一个已经被算法预先解释过的证据环境。

这一变化的关键之处在于，生成式 AI 并非简单地提供“更多信息”，而是提前完成了用户原本需要自己完成的一部分认识论工作。它帮助用户决定哪些证据更重要，哪些冲突可以被解释为例外，哪些不确定性可以被压缩为可理解的叙事，哪些结论在当前证据下显得更合理。对于用户而言，AI 输出的价值不仅来自信息量，也来自其形式上的

完整性、流畅性和解释性。一个结构清晰、语言自洽、逻辑连贯的 AI 答案，可能使用户产生一种主要信息已经被充分处理的感觉。

因此，生成式 AI 的社会科学意义不应仅仅被理解为信息获取成本下降。更重要的是，它可能改变个体在不确定性下形成信念的基本过程。在传统信念形成过程中，个体通常先面对证据的不完整性、异质性和冲突性，然后在这些不确定性中逐步形成判断。而在生成式 AI 环境中，个体可能先接触到一个看似完整的解释，再决定是否有必要回到证据本身。换言之，认知闭合可能发生在充分面对证据不确定性之前。

从行为经济学和信息经济学角度看，不确定性下的判断至少包含两个可区分的阶段。第一，个体决定是否继续获取信息。该阶段涉及额外信息价值、搜索成本和最优停止问题。第二，个体在获得新证据后如何更新信念。该阶段涉及证据诊断性、先验信念和贝叶斯更新问题。生成式 AI 的特殊性在于，它可能同时干预这两个阶段：一方面，AI 的综合性答案可能使用户误以为主要证据已经被充分覆盖，从而降低继续搜索的主观价值；另一方面，AI 的连贯叙事可能压缩问题中的模糊性和冲突性，从而降低用户对后续反向证据的更新幅度。

这也意味着，生成式 AI 的风险并不只是它是否会生成错误信息、偏见内容或幻觉事实。更隐蔽的风险在于，即使 AI 的答案并不明显错误，它仍然可能通过高度流畅和结构完整的解释形式，使用户过早相信自己已经理解了问题，或者相信主要证据已经被充分处理。此时，问题不再只是“用户是否采纳了错误答案”，而是“用户是否过早停止了证据搜寻”，以及“用户是否低估了后续反向证据的重要性”。

既有关于算法判断的研究主要关注人类是否信任、采纳或回避算法建议，例如算法厌恶、算法欣赏和自动化偏差 (Parasuraman & Riley, 1997; Lee & See, 2004; Dietvorst et al., 2015; Logg et al., 2019)。这些研究为理解人机决策提供了重要基础，但它们大多以传统算法建议为对象，即算法提供一个预测值、评分、分类结果、排序结果或推荐选项。

生成式 AI 与传统推荐算法的差异不只是算法更复杂，而是它改变了用户面对信息的形式和认识论关系。传统推荐系统主要通过排序、过滤和个性化推荐改变信息暴露结构，其核心作用是决定哪些离散信息项更容易进入用户视野 (Resnick & Varian, 1997; Adomavicius & Tuzhilin, 2005; Bozdag, 2013)。用户虽然受到排序和推荐影响，但通常仍然面对多个相对分离的信息入口，并需要自行比较、解释和整合。

生成式 AI 则进一步改变信息表达形态。它不是简单排列外部信息项，而是直接生成一个连续、流畅、结构完整的自然语言解释。由于 Transformer 架构、自回归语言建模、指令微调和人类反馈强化学习等技术机制，生成式 AI 的典型输出往往表现为上下文相关、语义连贯且具有“帮助感”的解释性文本 (Vaswani et al., 2017; Brown et al., 2020; Ouyang et al., 2022)。这意味着，生成式 AI 将证据选择、证据加权、冲突处理和结论生成折叠进同一个回答中，使用户在尚未充分接触原始证据之前，就已经面对一个看似完成综合判断的知识产品。

因此，生成式 AI 的影响不只是改变用户看到哪些信息，而是改变用户如何理解“这个答案是如何生成的”。用户面对传统推荐算法时，通常是在评估一个排序结果；而面对生成式 AI 时，用户更可能推断：AI 是否已经理解问题、是否已经看过足够证据、是否已经覆盖主要维度、是否已经处理反向证据，以及它的 summary 是否代表整个证据环境。这正是本文提出“感知信号结构”的理论起点。

为了刻画这一机制，本文提出“感知信号结构”的概念。所谓感知信号结构，是指用户在接触生成式 AI summary 后，对该 summary 背后信息生成过程的主观信念。具体而言，用户不仅会评估 AI 给出的结论是否可信，也会推断 AI 究竟观察了多少证据、覆盖了哪些证据维度、是否处理过反向信息、是否整合了不同来源、是否压缩了证据冲突，以及该 summary 是否能够代表更大的证据池。换言之，用户面对 AI 输出时，不只是接收一个答案，也在形成关于该答案背后信号生成过程的主观模型。

这一概念有助于区分本文与既有算法信任研究。生成式 AI 的影响并不完全来自“算法权威”，也不只是来自用户对 AI 结论的直接信任。即使用户并不完全相信 AI 的最终判断，他们仍然可能相信 AI 已经进行了充分搜索、筛选和综合；即使用户对 AI 保留一定怀疑，他们也可能因为认为 AI 已经处理过主要反向证据，而降低继续搜索的必要性和后续反证的诊断性。因此，生成式 AI 的关键影响不是简单地提高或降低用户对算法的信任，而是改变用户对当前证据环境本身的理解。

从信息经济学角度看，这一过程可以被理解为一种特殊的信息设计效应。经典 Bayesian persuasion 框架指出，信息发送者可以通过设计信号结构影响接收者的后验信念和行动选择 (Kamenica & Gentzkow, 2011)。更一般地，information design 研究关注信息设计者如何通过选择信息结构影响接收者在不确定性下的最优行为 (Bergemann & Morris, 2019)。本文借鉴这一思路，但将研究对象从外部发送者设计信号结构，推进到用户如何感知生成式 AI summary 背后的信号结构。

进一步地，non-Bayesian persuasion 研究表明，当接收者并非按照规范贝叶斯规则更新信念时，信息设计的效果取决于接收者系统性推断偏差的形式 (de Clippel & Zhang, 2022)。这一视角尤其适合分析生成式 AI 场景：AI 不只是传递信号，而是在生成 summary 的过程中重组信号结构；用户也不只是基于信号更新后验，而是在更新之前先形成关于 AI 信号生成过程的主观推断。由此，生成式 AI 的影响不只取决于实际信号结构，也取决于用户感知到的信号结构。

基于此，本文提出“感知信号结构与双重贝叶斯偏离”的理论框架。本文认为，生成式 AI 的答案优先综合可能通过两条机制路径影响人类在不确定性下的信念形成。

第一，在信息获取阶段，生成式 AI 可能诱发算法穷尽性错觉。由于 AI summary 通常以结构化、综合性和解释性的形式出现，用户可能高估其证据覆盖范围、样本量和代表性。他们可能认为 AI 已经搜索并整合了主要证据来源，已经比较了不同观点，并已经处理了关键冲突。由此，额外搜索的主观价值下降，继续获取信息的边际收益被低估，个体更容易过早停止证据抽样。

第二，在信念更新阶段，生成式 AI 可能产生模糊性压缩效应。AI 的连贯叙事往往会将分散、冲突和不确定的证据组织为一个较为清晰的解释框架。当用户相信 AI 已经处理过主要反向证据时，后续出现的反证可能被视为较低新颖性、较低代表性或较低诊断性的信号。结果是，用户虽然接触到了新的反向证据，却不会按照其客观信息含量充分修正原有信念，从而出现更新不足。

由此，生成式 AI 可能造成一种双重贝叶斯偏离。第一重偏离发生在信息获取阶段，表现为用户低估额外信号价值并过早停止搜索；第二重偏离发生在信息处理阶段，表现为用户低估反向信号诊断性并更新不足。本文所称的“双重贝叶斯偏离”并非仅指狭义上的后验更新偏误，而是指个体在信息获取和信念更新两个环节上同时偏离规范性的贝叶斯决策过程。

本文的核心理论主张是：生成式 AI 的关键影响并不只是改变用户接受什么答案，而是通过在证据之前提供连贯解释，改变人类在不确定性下的信息获取和信念更新规则。它可能使用户因为相信证据空间已经被充分覆盖而搜索更少，也可能使用户因为冲突证据已被压缩进既有叙事而更新更少。由此，生成式 AI 在算法权威之下造成一种双重贝叶斯偏离：同时改变信息获取和信息处理两个阶段。

二、文献综述

2.1 不确定性判断中的信息获取与证据抽样

不确定性下的信念形成并不是从最终判断开始，而是从“是否继续寻找证据”开始。个体最终相信什么，不仅取决于其如何解释已经看到的证据，也取决于其在判断形成之前看到了多少证据、看到了哪些证据，以及在什么时间点停止搜索。信息获取不是信念形成之前的中性准备环节，而是信念偏差产生的第一个关键位置。

从规范性角度看，信息搜索可以被理解为一个成本—收益权衡过程。当额外信息的预期价值高于获取成本时，继续搜索是合理的；当额外信息的边际价值低于搜索成本时，停止搜索也是合理的。理性忽视和 costly information acquisition 文献都强调，信息不是免费的，个体的注意力和搜索行为应当被理解为在成本约束下的信息选择过程（Sims, 2003; Caplin & Dean, 2015）。

经典决策研究也表明，人们在不确定性下并不会无成本、无限制地处理所有信息，而是会使用适应性搜索策略，根据任务复杂度、信息成本和预期收益决定何时停止搜索（Payne et al., 1993）。然而，现实中的停止规则并不总是符合规范性要求。个体可能因为确认偏误而更倾向于寻找支持既有观点的信息，也可能因为认知闭合需求而过早终止搜索，还可能因为最初获得的信息过于清晰、满意或连贯而降低继续探索的意愿（Nickerson, 1998; Lord et al., 1979）。

生成式 AI 为信息获取研究提出了一个新的问题：当用户在接触原始证据之前，已经看到一个高度结构化、连贯且看似综合充分的 AI summary 时，他们是否会系统性高估

当前证据状态的充分性？与传统搜索环境不同，AI summary 可能使用户感觉自己已经间接接触了一个更大的证据空间，即使他们实际上并未看到这些证据的分布、方差和冲突结构。

因此，本文认为，AI 可能通过改变用户对证据空间的主观想象而改变其停止规则。用户不是简单地因为“懒惰”而少搜索，而是因为他们推断 AI 已经完成了相当程度的信息搜索、筛选和整合。本文将这种机制纳入“感知信号结构”框架：如果用户认为 AI summary 来自更多证据、更广维度和更高代表性的证据基础，那么继续搜索的主观价值就会下降。

2.2 信念更新、证据诊断性与更新不足

信息获取之后，个体还需要根据已有证据形成或修正信念。在规范性贝叶斯框架下，个体应当根据新证据的诊断性调整后验信念。如果某一证据显著提高或降低某个假设成立的概率，那么个体的后验判断也应相应发生变化。

但大量行为决策研究表明，人类的信念更新经常偏离规范性贝叶斯规则。个体可能表现出保守性，即面对新证据时调整不足；也可能受到锚定效应影响，使后续判断过度依赖初始信息；还可能通过动机性推理或确认偏误降低反向证据的权重。这些偏差说明，信念更新不仅取决于证据本身的客观诊断性，也取决于个体如何理解该证据与已有解释框架之间的关系。

这一点对本文尤为重要。反向证据并不会自动改变个体信念。它必须首先被个体识别为“相关的”“可信的”“具有诊断性的”证据，才可能产生充分的更新作用。如果个体认为反向证据只是例外、噪音、边界情况或已经被原有叙事吸收的信息，那么即使该证据在客观上具有较高诊断性，个体也可能不会给予足够权重。

既有信念更新文献较多关注个体先验、动机、认知能力或信息呈现方式对更新的影响，但较少分析生成式 AI 提前生成的解释框架如何改变用户对后续证据的诊断性感知。本文认为，这是理解 AI 影响人类判断的第二个关键缺口。生成式 AI 不仅可能影响用户是否继续搜索证据，也可能影响用户在看到相同证据之后如何解释这些证据。

由此，本文提出“模糊性压缩”这一机制：生成式 AI 通过提供连贯、完整、可读的解释叙事，将原本异质、冲突和概率性的证据组织成一个更稳定的理解框架。该框架可能降低用户对未解决不确定性和证据冲突的感知，从而使后续反向证据显得不那么重要、不那么具有代表性，或者不足以改变原有判断。

2.3 算法建议、算法信任与算法权威

关于人类如何回应算法输出，已有研究主要围绕算法建议、算法信任、算法厌恶、算法欣赏和自动化偏差展开。相关研究表明，人类并不会稳定地信任或排斥算法。有时，人们在看到算法犯错后会过度回避算法判断；有时，人们又会认为算法比人类更

客观、更准确，并因此更愿意采纳算法建议。自动化偏差研究进一步说明，在某些场景中，人类可能过度依赖自动化系统，从而忽视自身判断或外部证据。

这些研究为理解人机决策关系提供了重要基础，但它们通常将算法输出理解为一个预测、评分、分类结果或推荐选项。因此，研究重点往往是用户是否采纳算法建议、是否调整自己的判断、是否过度依赖算法或是否在算法犯错后产生厌恶。换言之，既有研究主要关注算法输出对最终判断或选择的影响。

生成式 AI 的特殊性不仅在于它给出解释，更在于它容易被用户理解为一种具有知识状态和判断能力的认识论代理。传统推荐算法通常被理解为排序工具、过滤器或决策辅助系统；而生成式 AI 以自然语言对话方式与用户互动，能够解释、追问、修正、总结和回应具体语境。这种交互形式使用户更容易将其理解为一个已经“看过”“理解过”“判断过”的准主体，而不是一个中性的计算工具。

人机交互研究长期表明，人类会将社会规则和社会期待应用于计算机系统。CASA 范式指出，当计算机表现出语言、回应性、互动性或社会线索时，人们会无意识地将其实当作社会行动者对待（Reeves & Nass, 1996; Nass & Moon, 2000）。社会认知研究也表明，人类会根据对象的互动性、目标导向性和行为复杂性进行拟人化和心智归因，即推断其“知道什么”“理解了什么”以及“是否已经考虑过某些信息”（Epley et al., 2007; Waytz et al., 2010）。

这一点在生成式 AI 场景中尤其重要。Woodruff and Hewitt (2026) 指出，LLM 虽然能够生成流畅且看似有知识含量的回答，但其输出并不满足 reflective regulation、resistance to revision 和 normative commitment 等知识条件，因此不应被设计或理解为 epistemic authority，而应作为支持探究的 knowledge-building partner。Qi and Pan (2026) 在循证医学场景中也指出，通用 LLM 能够生成医学上看似合理的 evidence-related outputs，但在来源可验证性、方法严谨性和责任归属方面仍存在限制。

因此，本文所说的算法权威不是一般意义上的“相信 AI 答案正确”，而是用户将 AI 视为已经替自己完成证据搜索、证据综合和初步判断的认识论代理。用户面对生成式 AI 时，可能不只是问“这个答案对不对”，而是推断“它是否已经看过足够多证据”“它是否已经考虑了反方观点”“它是否已经替我完成了综合判断”。这些推断构成本文所谓的感知信号结构。

由此，本文对算法建议文献的推进在于：既有研究主要解释人类是否接受算法输出，而本文关注算法权威如何改变人类对证据充分性和证据诊断性的判断。

2.4 生成式 AI、信息设计与非贝叶斯说服

信息设计文献研究的是：一个掌握信息呈现权的发送者如何通过设计信号结构来影响接收者的信念和行动。在经典 Bayesian persuasion 框架中，Sender 并不直接控制

Receiver 的行动，而是通过选择信息结构影响 Receiver 所形成的后验信念，进而影响其行动选择 (Kamenica & Gentzkow, 2011)。后续 information design 文献进一步将这一思想扩展为一个统一框架，用于分析信息结构、后验信念和行为反应之间的关系 (Bergemann & Morris, 2019)。然而，这一传统框架通常假设 Receiver 能够按照贝叶斯规则正确理解信号。现实中的个体则经常在概率推断中出现系统性偏离，因此 *Non-Bayesian Persuasion* 进一步指出，当 Receiver 不是贝叶斯更新者时，其实际后验可以被理解为规范 Bayesian posterior 经过某种 distortion function 后的结果 (de Clippel & Zhang, 2020)。

本文借鉴这一思想，但将其推进到生成式 AI 场景。生成式 AI 并不是传统推荐算法的简单延伸。传统推荐系统、搜索引擎和新闻流算法主要通过排序、过滤和个性化推荐改变用户的信息暴露结构，其核心作用是决定哪些离散信息项更容易进入用户视野 (Resnick & Varian, 1997; Adomavicius & Tuzhilin, 2005; Bozdog, 2013)。在这类系统中，用户虽然受到排序和推荐影响，但通常仍然面对多个相对分离的信息入口，例如链接、商品、文章、视频或评分，并需要自行比较、解释和整合这些信息。换言之，传统推荐算法主要改变的是用户“看见什么”和“先看什么”。

生成式 AI 的关键差异在于，它进一步改变了信息的表达形态和认识论关系。它不是简单排列外部信息项，而是直接生成一个连续、流畅、结构完整的自然语言解释。由于 Transformer 架构、自回归语言建模、指令微调和基于人类反馈的强化学习等技术机制，生成式 AI 的典型输出往往表现为上下文相关、语义连贯、语气自然且具有“帮助感”的解释性文本 (Vaswani et al., 2017; Brown et al., 2020; Ouyang et al., 2022)。因此，用户面对的不是一组等待进一步判断的信息来源，而是一个已经被模型组织、压缩和叙事化的综合回答。生成式 AI 将传统上分散在多个认知环节中的操作——证据选择、证据加权、冲突处理、因果解释和结论生成——折叠进同一个输出之中。

这一点使生成式 AI 具有不同于传统推荐算法的说服结构。传统推荐算法可能影响用户的信息暴露，但通常仍保留多个信息项之间的可见分离；生成式 AI 则将异质证据、冲突信息和不确定性整合为一个表面连贯的解释性叙事。叙事传输理论表明，连贯叙事能够通过吸收注意力、情感和想象来影响个体信念，并降低反驳和批判性评估倾向 (Green & Brock, 2000)。在生成式 AI 场景中，这种机制可能被进一步放大：AI 输出的并不是零散证据，而是一个已经完成初步意义建构的解释框架。用户因此可能更容易将其理解为一个稳定的后验判断，而不是一个仍需检验的假设。

然而，生成式 AI 的形式连贯性并不等于真实理解或充分证据综合。大型语言模型能够生成高度流畅的文本，但流畅的语言形式并不保证其具有语义 grounding、事实敏感性或证据敏感的判断能力。Bender et al. (2021) 对大型语言模型提出的批判正是基于这一点：语言模型主要在语言形式层面进行生成，人类却容易从流畅句法和连贯语篇中推断出意义理解和知识处理。也就是说，生成式 AI 的风险不只是它可能生成错误内容，而是其流畅性和完整性可能被用户误读为系统已经充分处理了底层证据。

更进一步，生成式 AI 还可能被用户理解为一种具有知识状态和判断能力的认识论代理。传统推荐算法通常被视为后台排序器、过滤器或辅助工具，而生成式 AI 通过自然语言对话回应用户，能够解释、修正、总结、承认不确定性，并根据上下文调整回答。人机交互研究表明，当计算机系统表现出语言、回应性和社会线索时，人类会倾向于将社会规则应用于这些系统，并将其视为社会行动者（Reeves & Nass, 1996; Nass & Moon, 2000）。社会认知研究也表明，人类会根据对象的互动性、目标导向性和行为复杂性进行拟人化和心智归因，即推断其“知道什么”“理解了什么”以及“是否已经考虑过某些信息”（Epley et al., 2007; Waytz et al., 2010）。因此，用户面对生成式 AI 时，往往不只是评估一个答案是否正确，而是在推断 AI 是否已经理解了问题、是否已经看过主要证据、是否已经考虑了反方观点，以及是否已经替自己完成了综合判断。

这一区别对本文至关重要。生成式 AI 的影响并不只是改变用户接触到哪些信息，而是改变用户对“信号是如何生成的”的理解。用户可能把 AI summary 理解为来自更大证据空间、更广证据维度和更充分反证处理的综合信号，从而高估其代表性。本文将这种主观推断称为**感知信号结构**。在这一意义上，生成式 AI 不只是一个信息源，而是一个改变用户信号结构感知的信息设计者。

因此，生成式 AI 场景为 information design 和 non-Bayesian persuasion 文献提出了一个新的问题。传统 persuasion 模型通常关注 Sender 如何设计信号，以及 Receiver 如何在观察信号后形成后验信念；而生成式 AI 场景中，用户不仅接收一个信号，还会对该信号的生成过程形成主观推断。用户可能推断 AI summary 来自多大范围的证据、是否覆盖了主要维度、是否处理过反向信息，以及该 summary 是否足以代表整体证据环境。本文将这类主观推断称为**感知信号结构**。

这一视角并不意味着生成式 AI 必然导致非贝叶斯偏离，而是指出一个尚未被充分研究的机制可能性：生成式 AI 的连续解释和对话式呈现，可能使用户高估 AI summary 的证据覆盖范围和反证处理程度。若这种感知发生，用户可能在信息获取阶段降低继续搜索的主观价值，也可能在后续看到反向证据时降低其主观诊断性。由此，本文将进一步考察：生成式 AI 是否通过改变用户的感知信号结构，影响其证据抽样和贝叶斯更新过程。

2.5 文献缺口与本文定位

综上，现有文献为本文提供了重要基础，但仍留下一个尚未充分解释的理论缺口：既有研究较少分析生成式 AI 如何改变用户对“信号是如何生成的”的主观理解，并进一步影响其信息获取和信念更新过程。

第一，信息获取与证据抽样文献表明，个体是否继续搜索取决于其对额外信息价值、搜索成本和当前证据充分性的判断。然而，这类研究通常关注个体自身的搜索成本、注意力限制或动机偏差，较少分析当生成式 AI 在用户接触原始证据之前提供一个综合性解释时，用户是否会高估当前信息状态的充分性。换言之，现有研究尚未充分解

释：用户是否会因为认为 AI 已经覆盖并整合了主要证据，而提前降低继续搜索的主观价值。

第二，信念更新文献表明，人们面对新证据时可能出现保守更新、确认偏误或反向证据低权重化，且证据的主观诊断性会影响后验调整。然而，这类研究较少考察生成式 AI 预先生成的连贯解释框架如何改变用户对后续证据的理解。尤其是，当用户认为 AI 已经考虑过反向证据时，后续出现的反向信息可能不再被视为新的、高诊断性的证据，而是被理解为已经被原有叙事吸收的局部例外。

第三，算法建议和算法信任文献主要关注用户是否采纳、修正或回避算法输出，但大多仍将算法输出理解为一个预测、评分、推荐或分类结果。生成式 AI 的特殊性在于，它不仅给出结论，还以自然语言形式组织证据、解释因果关系、处理冲突并生成连贯叙事。因此，关键问题不只是用户是否相信 AI 的答案，而是用户如何理解该答案背后的证据基础：AI 是否看过足够多证据？是否覆盖了主要维度？是否处理过反向信息？其 summary 是否能够代表整体证据环境？

第四，生成式 AI 相关研究已经关注偏见、幻觉、自动化偏差、叙事说服和理解幻觉，但仍需要进一步打开这些现象背后的行为机制。现有研究已经说明 AI 输出可能影响判断，却较少区分两类不同的偏离来源：用户最终判断出现偏差，究竟是因为他们在前期获取了更少证据，还是因为他们在后期面对相同证据时给予了更低权重？这一区分对于理解 AI 影响信念形成的机制和设计相应治理方案都至关重要。

本文正是在这一缺口上展开。本文不把生成式 AI 仅仅视为一个提供建议的工具，而是将其理解为一种能够改变用户信号环境和信号理解方式的意义建构系统。本文提出“感知信号结构”这一概念，用以描述用户对 AI summary 背后证据生成过程的主观推断，包括其感知样本量、覆盖广度、代表性、反证处理程度和压缩损失。本文认为，生成式 AI 的答案优先综合可能通过改变用户的感知信号结构，同时影响两个环节：在信息获取阶段，它可能使用户高估 AI summary 的证据覆盖范围和代表性，从而降低继续搜索的主观价值；在信息处理阶段，它可能使用户认为反向证据已被 AI 预先考虑或吸收，从而降低后续反证的主观诊断性。

因此，本文研究的不是 AI 是否一般性地影响人类判断，而是一个更具体的机制问题：生成式 AI 如何通过改变用户对信号生成过程的理解，影响其在不确定性下对证据充分性和证据诊断性的判断，并进一步导致证据抽样不足与信念更新不足。

三、理论框架

3.1 生成式 AI 作为算法意义建构代理

本文将生成式 AI 理解为一种特殊的信息设计者。它与传统推荐算法的区别不在于是否会筛选信息，而在于它以连续自然语言形式生成一个看似完整的解释结构。传统推荐算法主要改变离散信息项的排序和可见性；生成式 AI 则把证据选择、证据加权、冲突

处理和结论生成压缩进同一个回答，使用户在接触原始证据之前就面对一个“已经被解释过”的信息环境。

更重要的是，生成式 AI 的对话界面会诱导用户对其知识状态进行推断。用户并不只是看到一个答案，而是可能认为这个答案背后已经存在大量证据处理、跨维度比较和反证吸收。因此，生成式 AI 的信息设计作用不只是改变用户看到什么，而是改变用户以为系统已经看过什么、理解了什么和综合了什么。

在传统信念形成过程中，顺序通常是：

证据 → 解释 → 判断

而在生成式 AI 环境中，顺序更接近：

AI 判断 → AI 解释 → 可选的证据核查

这一顺序逆转是本文理论框架的关键。用户可能先接触一个看似完整的后验判断，再决定是否继续接触底层证据。于是，认知闭合可能发生在充分面对不确定性之前。

3.2 算法权威与证据充分性感知

本文将算法权威定义为用户对 AI 在信息搜索、证据整合和判断生成方面具有较高能力的主观认知。算法权威并不等同于简单信任。简单信任关注的是“AI 的答案是否正确”；算法权威关注的是“AI 是否已经替我充分处理了证据环境”。

这个区别十分关键。用户即使并不完全相信 AI 的最终结论，也可能相信 AI 已经检索并整合了主要信息。因此，AI 的影响可能不表现为直接采纳答案，而表现为降低继续搜索的意愿。换言之，算法权威首先影响的是用户对证据充分性的判断。

在不确定性决策中，个体是否继续搜寻信息，取决于其对额外信息价值的判断。若个体认为继续搜索仍可能显著改变判断，则继续抽样是合理的；若个体认为现有信息已经足够，则停止搜索也是合理的。问题在于，AI 的综合性输出可能使用户高估当前信息状态的充分性，从而过早降低额外信息的主观价值。

因此，算法权威的核心作用在于改变用户对以下问题的回答：

我是否还需要更多证据？
当前答案是否已经足够全面？
继续搜索是否仍然值得？

这意味着，AI 的影响不是简单地把用户推向某一个具体答案，而是改变用户对“证据是否已经足够”的判断。它影响的是信念形成过程中的停止规则，而不仅仅是最终选择。

3.3 路径一：算法穷尽性错觉与信息获取偏离

第一条机制路径发生在信息获取阶段。本文将算法穷尽性错觉定义为：用户相信 AI 生成的答案已经覆盖、筛选并整合了足够广泛的证据空间，即使实际上 AI 并未真正穷尽相关证据。

这种错觉并不一定来自用户对 AI 的盲目信任，而可能来自 AI 输出本身的形式特征。生成式 AI 的回答通常结构清晰、语言流畅、论证完整，并且倾向于以总结性的方式呈现不同因素。正是这种完整性形式，容易让用户产生一种“主要信息已经被处理过”的感觉。

算法穷尽性错觉会降低用户对额外信息的感知价值。用户可能认为，继续搜索只会获得重复性或边际价值较低的信息，而不会显著改变当前判断。由此，用户更可能提前停止信息搜寻，抽取更少证据，并更快进入最终决策。

这一机制链条可以概括为：

AI 答案优先综合
→ 算法权威
→ 算法穷尽性错觉
→ 额外信息感知价值下降
→ 过早停止搜索
→ 内生证据抽样不足

这一路径解释的是：AI 如何使用户“看得更少”。

需要强调的是，这种行为不一定表现为主观上的懒惰或非理性。对用户而言，如果他们相信 AI 已经完成了足够全面的信息整合，那么减少搜索可能是一个看似合理的选择。真正的问题在于，AI 输出的“形式完整性”可能被误读为“证据完整性”。

3.4 路径二：模糊性压缩与信息处理偏离

第二条机制路径发生在信息处理阶段。本文将模糊性压缩定义为：AI 将异质、冲突和概率性的证据转化为高度连贯的解释叙事，从而降低用户对未解决不确定性和证据冲突的感知。

复杂问题通常包含多种可能解释。证据可能不完整、彼此冲突，或在不同条件下指向不同结论。传统上，这种模糊性会提醒用户保持判断开放，并在新证据出现时进行修正。然而，生成式 AI 往往倾向于提供清晰、可读、连贯的回答。为了生成“有帮助”的答案，AI 可能会将冲突证据纳入一个统一叙事中，将反例解释为边界条件、例外情况或次要因素。

例如，AI 可能会说：

虽然存在一些反例，但总体趋势仍然支持该判断。
虽然证据并不完全一致，但更合理的解释是.....
这些差异主要来自情境因素，并不改变核心结论。

这些表述不一定错误，但它们会改变用户对冲突证据的心理感知。原本可能具有强诊断性的反向证据，可能被重新理解为局部异常、背景噪音或已被主叙事吸收的信息。

由此，AI 可能不仅影响用户看到多少证据，也影响用户如何解释已经看到的证据。即使用户之后接触到新的反向信息，他们也可能低估该信息对原有判断的挑战性，从而产生信念更新不足。

这一机制链条可以概括为：

AI 答案优先综合
→ 连贯解释叙事
→ 模糊性压缩
→ 反向证据感知诊断性下降
→ 信念更新不足
→ 贝叶斯更新偏离

这一路径解释的是：AI 如何使用户“更新得更少”。

3.5 双重贝叶斯偏离

本文的核心理论概念是双重贝叶斯偏离。该概念指的是，生成式 AI 可能在人类信念形成的两个阶段同时造成偏离：一是在信息获取阶段导致抽样不足，二是在信息处理阶段导致更新不足。

第一重偏离是信息获取偏离。在规范性意义上，一个理性决策者应当在额外信息的预期价值高于搜索成本时继续搜寻证据。如果 AI 的综合性答案使用户误以为证据已经充分，从而在尚未获得足够信息之前停止搜索，那么就会产生信息获取侧的偏离。

第二重偏离是信息处理偏离。在规范性贝叶斯框架下，个体在观察到新证据后，应根据该证据的诊断性调整后验信念。若后续反向证据具有较高诊断性，但用户因为此前接受了 AI 的连贯解释而更新不足，那么就会产生信息处理侧的偏离。

双重贝叶斯偏离的理论意义在于，它区分了两类常常被混淆的错误来源：

错误类型一：用户没有获得足够多的证据。
错误类型二：用户获得了证据，但没有给予足够权重。

前者是信息获取问题，后者是信息处理问题。二者都可能导致后验信念偏差和决策质量下降，但其机制和治理方案不同。若问题在于抽样不足，干预应鼓励用户继续搜索

或展示证据空间的不完整性；若问题在于更新不足，干预则应提高冲突证据的显著性和诊断性。

因此，本文的理论框架可以概括为：



四、研究问题

本文的总研究问题是：

生成式 AI 的答案优先综合如何通过改变证据抽样、模糊性感知与信念更新，重塑人类在不确定性下的信念形成过程？

更具体地说，本文关注以下研究问题：

RQ1：生成式 AI 的答案优先综合是否会改变用户的感知信号结构？

该问题关注用户如何理解 AI summary 背后的证据生成过程。关键不在于用户是否完全相信 AI 的最终结论，而在于用户是否认为 AI 已经查看了更多证据、覆盖了更多证据维度、处理了主要反向证据，并生成了能够代表整体证据环境的综合性总结。

RQ2：感知信号结构是否会降低继续搜索的主观价值？

该问题关注信息获取阶段的心理机制。若用户认为 AI summary 已经充分覆盖并整合了相关证据，他们可能认为继续搜索只会带来重复性、边际价值较低的信息，从而降

低额外证据的感知价值。

RQ3：生成式 AI 是否会通过感知信号结构导致证据抽样不足？

该问题关注核心行为结果。若 AI answer-first 条件下的用户自愿抽取更少证据、更早停止搜索，并且这种效应由感知信号结构和感知信息价值解释，则说明生成式 AI 不只是影响最终判断，也改变了用户的信息获取规则。

五、研究假设

5.1 感知信号结构路径

H1：相比传统搜索式或证据列表式信息呈现，AI answer-first 会增强用户的感知信号结构膨胀。

具体而言，AI answer-first 条件下的用户会认为 summary 来自更多证据、更广证据维度、更高代表性的信息基础，并且更可能认为 AI 已经处理了主要反向证据。

H2：感知信号结构膨胀会降低继续搜索的感知信息价值。

用户越认为 AI summary 已经充分覆盖并代表整体证据池，就越倾向于认为继续抽取额外证据的边际价值较低。

H3：AI answer-first 会导致用户自愿抽样数量下降。

相比证据列表、搜索式呈现或无 summary 条件，AI answer-first 条件下的用户会自愿抽取更少数量的额外证据，并更早停止信息搜索。

H4：感知信号结构和感知信息价值中介 AI answer-first 对证据抽样不足的影响。

AI answer-first 并非简单地使用户“懒于搜索”，而是通过改变用户对 AI summary 背后证据覆盖范围、代表性和反证处理程度的主观理解，降低继续搜索的必要性感知，从而导致抽样不足。

机制链条为：

```
AI answer-first
→ 感知信号结构膨胀
→ 额外信息感知价值下降
→ 自愿抽样数量下降
```

5.2 信号结构校准路径

H5：信号结构校准提示能够削弱 AI answer-first 对抽样不足的影响。

如果 AI summary 明确披露其证据覆盖范围有限、并不代表全量证据，或提示可能存在尚未处理的反向证据，则用户的感知信号结构膨胀会减弱，继续搜索的感知价值会提高，自愿抽样数量也会增加。

机制链条为：

信号结构校准提示
→ 感知信号结构膨胀下降
→ 额外信息感知价值上升
→ 自愿抽样数量上升

5.3 排除性检验

H6：AI answer-first 对抽样不足的影响不能完全由一般算法信任或初始答案锚定解释。

在控制用户对 AI 准确性的信任、对初始结论的信心、以及初始答案方向和强度后，感知信号结构仍应显著预测继续搜索的感知价值和自愿抽样数量。

六、核心理论贡献

本文试图对现有关于 AI 与人类判断的研究作出三方面贡献。

第一，本文将生成式 AI 从“算法建议”重新界定为“算法意义建构代理”。既有研究多关注用户是否采纳算法输出，而本文强调，生成式 AI 的影响发生在更早的问题理解与证据组织阶段。它不只是提供答案，而是为用户预先组织证据、压缩冲突并生成解释框架。

第二，本文将 AI 对人类判断的影响分解为信息获取和信息处理两个阶段。通过提出“算法穷尽性错觉”和“模糊性压缩”两个机制，本文区分了用户“看得更少”和“更新得更少”两类偏离。这一区分有助于避免将 AI 影响简单归因为信任、懒惰、锚定或自动化偏差。

第三，本文提出“双重贝叶斯偏离”的理论框架，将生成式 AI 的行为影响嵌入信息获取、最优停止和贝叶斯更新的规范性框架之中。这一框架不仅有助于解释 AI 如何改变个体信念形成，也有助于评估其潜在福利后果和治理方案。

简言之，生成式 AI 的关键影响并不只是改变用户接受什么答案，而是改变用户如何判断证据是否充分、冲突是否重要、以及信念是否需要修正。生成式 AI 正在把人类从“基于证据形成判断”的主体，转变为“基于算法解释管理证据”的主体。本文研究的正是这一认知秩序转变的行为机制与决策后果。

9. Research Design Overview

本文包含三项实验研究。

Study	目标	核心设计	核心贡献
Study 1	检验双重贝叶斯偏离	两阶段序贯抽样 + Yoked control + logit updating	区分 acquisition 与 processing
Study 2	识别 AI-specific 机制	结构性操纵穷尽性线索与模糊性压缩	检验算法穷尽性错觉与模糊性压缩

10. Study 1：双阶段序贯抽样主实验

10.1 研究目的

Study 1 检验生成式 AI 是否造成双重贝叶斯偏离：

阶段一：AI 是否导致过早停止证据抽样？

阶段二：AI 是否导致对高诊断性反向信号的 log-odds 更新不足？

Study 1 分为 Study 1a 和 Study 1b。

Study 1a：自然序贯抽样，估计 AI 对完整信念形成过程的总效应。

Study 1b：Yoked control，控制信息集大小后识别 processing bias 的直接效应。

10.2 实验场景

首选场景：

企业违约风险判断

理由：

可以自然设定先验概率；

可以设计正反证据；

可以赋予证据似然比；

可以要求被试报告概率；

可以设计投资/避险决策；
可以使用代币激励计算净收益。

任务示例：

被试需要判断某企业未来一年是否会进入高违约风险状态。系统提供一个大型研报数据库，被试可以付费查看证据，并最终报告该企业属于高违约风险类型的概率。

本文使用：

研究者可控、被试看似开放的证据池

被试看见的是：

你永远无法向审稿人证明“高管离职”这条证据的客观强度到底是多少，因为自然语言存在极大的语义模糊性（Semantic Ambiguity），不同被试内心的先验映射完全不同。如果你连客观的贝叶斯基准（Normative Baseline）都算不准，你后续所有的“偏离度（Deviation）”计算都是空中楼阁。

【学术界的先例】

这种设计在学术界不仅有先例，而且是一个极其经典且庞大的研究分支：**序贯抽样范式（Sequential Sampling Paradigm）与主动信息获取（Active Information Acquisition）**。

- **心理学/决策科学根基**：经典的“坛子抽球实验（Urn Experiments）”（Edwards, 1965）。
- **信息系统/行为过程**：经典的 **Mouselab** 追踪技术（Payne et al., 1993），研究者通过隐藏信息，要求被试必须点击才能看到具体数值，以此计算搜寻成本和停止点。
- **现代宏观/行为经济学前沿**：理性忽视（Rational Inattention）框架下的信息选择实验（如 Caplin & Dean, 2015; Enke & Zimmermann, 2019）。

这些顶刊 paper 能够跑通证据池实验，绝对不是靠让被试读长篇大论，而是遵循了一个铁律：**剥离语义，诉诸数据生成过程（Data Generating Process, DGP）**。

【如何量化证据强度：破局法则】

为了实现“研究者绝对可控，被试看似开放”，你必须把“文本研报”降维成“带有明确似然比（Likelihood Ratio, LR）的结构化信号”。

在实验指导语中，你必须**向被试公开信号生成的条件概率矩阵**。

这是唯一能让所有被试拥有统一客观似然函数的办法。

具体操作示范：

不要说：“你可以在数据库里查阅研报”。

应该说：“该数据库包含 50 个独立的自动风控指标（如：现金流预警系统、供应链舆情监控等）。历史数据显示，这些指标具有不完美的诊断准确率。”

接着，强行规定 $P(\text{Signal} \mid \text{State})$ ：

- 如果企业真实状态是 **【高违约风险】**，那么数据库中抽出的任何一个指标，有 **70%** 的概率显示“红灯（负面）”，30% 的概率显示“绿灯（正面）”。
- 如果企业真实状态是 **【低违约风险】**，那么抽出的任何一个指标，有 **30%** 的概率显示“红灯”，70% 的概率显示“绿灯”。

证据强度的完美量化：

此时，每当被试花钱抽到一个“红灯（负面指标）”，这条证据的强度就变成了纯粹的数学常数，根本不需要你用主观判断：

$$\$LR_{\text{负面}} = \frac{P(\text{红灯} \mid \text{高风险})}{P(\text{红灯} \mid \text{低风险})} = \frac{0.7}{0.3} = 2.33\$$$

同理，抽到一个“绿灯”的强度：

$$\$LR_{\text{正面}} = \frac{P(\text{绿灯} \mid \text{高风险})}{P(\text{绿灯} \mid \text{低风险})} = \frac{0.3}{0.7} = 0.43\$$$

【最强 Study 1 落地设计】

为了让这个数学模型拥有“AI 研报”的生态效度（Ecological Validity），你需要做一层 UI 上的“贴图包装”：

1. 底层逻辑（完全受控）：

你预先设定好真实状态（例如该企业其实是低风险）。你设定被试的抽样池里，红灯绿灯的生成严格遵循上述概率分布。每一次抽样的贝叶斯后验演进路线，你在后台了如指掌。你能精确算出，在代币成本 $\$c\$$ 之下，最优停止抽样点 $\$N^*\$$ 是多少次。

2. 表层呈现（看似开放）：

被试点击【抽取证据】时，系统弹出的不仅是一个“红灯”，而是一段“结构化摘要”。

- *内部代码：生成了红灯*
- *前端显示：“指标 #12（流动性压力测试）：**未能通过**。详情：AI 分析显示短期偿债能力处于历史低位区间。（历史准确率参数：70%）”*
- *内部代码：生成了绿灯*

- **前端显示：**“指标 #45（核心资产抵押率）：**通过**。详情：AI 分析显示抵押物价值稳定，未见异常折损。（历史准确率参数：70%）”

3. AI 综合组的处理：

- 在进入抽样池之前，AI 先跳出来讲：“基于对数据库底层 50 个指标的快速全量扫描，本 AI 认为该企业存在较高违约风险。虽然局部指标（如核心资产）表现尚可，但主导性趋势（流动性等）严重恶化。”
- **这里的核心就是：**AI 的文本极度连贯（高模糊性压缩），并且暗示它已经看完了全部 50 个球（算法穷尽性错觉）。

【导师会如何评价这个设计】

当你把这套 DGP（数据生成过程）写进 Proposal 时，审稿人和导师的疑虑会瞬间打消：

1. **你解决了内生性：**所有证据的 LR 是预先给定的数学事实。
2. **你获得了黄金基准：**因为 LR 固定，你可以画出一条绝对标准的贝叶斯后验概率曲线，把被试的主观报告值直接与其相减，得出无懈可击的 \$Bayesian Deviation\$。
3. **保留了实验的张力：**被试依然觉得自己在一个庞大的金融数据库里翻找资料，保留了业务场景的真实感，但你的后台是一个极其干净的统计学“抽球罐子”。

一个大型研报数据库；
数据库中包含大量关于该企业的相关证据；
每次点击可以查看一条证据；
每次查看需要支付少量代币；
最终判断越准确，奖励越高。

研究者后台控制：

证据生成分布；
每条证据方向；
每条证据似然比；
证据之间的局部方差；
高诊断性外生 shock 的 LR；
最优抽样数量 N^* ；
规范贝叶斯后验概率。

这样可以同时保留：

生态效度：用户以为自己面对开放信息环境；
内部效度：研究者知道证据结构和规范贝叶斯基准。

10.4 Study 1a：自然序贯抽样

实验条件

条件	描述	功能
AI answer-first	先看 AI 综合研判，再自由抽样	主 treatment
Human expert answer-first	先看人类专家综合研判，再自由抽样	区分 AI-specific 与 structured synthesis
Search-only free	无综合研判，自由抽样	自然搜索基线
AI answer-last	先自由抽样，再看 AI 综合研判	区分 answer-first 与 AI exposure

阶段一：内生抽样

流程：

1. 给出基础事件和先验概率；
2. 根据条件呈现 AI / 专家综合判断或不呈现；
3. 用户进入证据池；
4. 每查看一条证据需要支付代币；
5. 用户可随时停止；
6. 停止后报告 interim belief。

核心测量：

Nactual：实际自愿抽样数量
Stopping point：停止点
Search cost：搜寻成本
Perceived VOI：继续搜寻的感知信息价值
Algorithmic exhaustiveness：算法穷尽性错觉
Interim belief：中间后验概率
Interim confidence：中间信心

核心因变量：

$$\text{Sampling Deviation} = N^* - N_{\text{actual}}$$

其中：

N^* = 给定搜寻成本与错误损失下的规范最优抽样数量

如果：

$$N_{\text{actual}} < N^*$$

说明存在内生抽样不足。

阶段二：外生冲击

在被试自愿停止并报告 interim belief 后，系统强制推送一条或一组高诊断性反向证据。

关键设计：

所有被试看到相同类型的 shock；
shock 的 LR 由研究者预设；
shock 被设定为条件独立于阶段一已抽样信号；
以被试自己的 interim belief 作为 prior；
用 log-odds 形式计算规范更新。

流程：

1. 用户已报告 interim belief；
2. 系统推送 high-LR disconfirming shock；
3. 用户报告 final belief；
4. 计算 logit updating deviation；
5. 用户做最终决策；
6. 根据决策准确性、搜寻成本和错误损失计算净收益。

10.5 Study 1b：Yoked Control Processing Test

研究目的

Study 1a 能估计 AI 对最终结果的总效应，但阶段一抽样数量不同可能影响阶段二处理。为了干净识别 processing bias，需要 Study 1b 控制信息集大小。

条件设计

条件	描述
AI answer-first	先看 AI 综合研判，自由抽样
Search-only yoked	不看 AI，但被分配与 AI 组相同数量的证据

Yoked control 逻辑

如果 AI 组某被试在：

N = 2

时停止，则 Yoked Search-only 组对应被试也只看到：

N = 2

条证据，然后进入同样的外生冲击阶段。

这样可以保证：

AI 组和 Yoked 组进入阶段二前的信息集大小相同。

如果此时 AI 组仍然表现出更弱的 log-odds updating，则说明：

差异不是由“AI 组读得少”造成，而更可能来自 AI 早期叙事对证据处理权重的影响。

实施方式

可以采用两种方案。

方案一：实时配对

根据 AI 组实际停止点，实时分配 Yoked 被试。

优点：

个体级配对最严格。

缺点：

实验执行复杂。

方案二：预实验分布配对

先通过 pilot 得到 AI 组的抽样数量分布，再让 Yoked 组按该分布被动接收证据。

优点：

执行稳定。

缺点：

不是完全个体级配对。

| pilot-based yoked distribution，并在稳健性检验中使用 individual matching。

10.6 Study 1 的核心指标

信息获取阶段

Voluntary Sample Size = Nactual
自愿抽样数量

Sampling Deviation = $N^* - N_{actual}$
抽样偏离度

Search Cost
搜寻成本

信息处理阶段

主指标使用 log-odds updating deviation。

$$\text{logit}(P) = \ln(P / (1 - P))$$

实际更新：

$$\begin{aligned} \text{Actual Logit Update}_i \\ = \text{logit}(P_{\text{final}_i}) - \text{logit}(P_{\text{interim}_i}) \end{aligned}$$

规范更新：

$$\begin{aligned} \text{Normative Logit Update} \\ = \log(\text{LRshock}) \end{aligned}$$

更新偏离：

$$\begin{aligned} \text{Updating Deviation}_i \\ = | [\text{logit}(P_{\text{final}_i}) - \text{logit}(P_{\text{interim}_i})] - \log(\text{LRshock}) | \end{aligned}$$

隐含权重：

$$w_i = [\text{logit}(P_{\text{final}_i}) - \text{logit}(P_{\text{interim}_i})] / \log(\text{LRshock})$$

解释：

$w_i = 1$: 完全按照贝叶斯规则吸收 shock ;
 $0 < w_i < 1$: 低估 shock 权重 ;
 $w_i \approx 0$: 几乎没有更新 ;
 $w_i < 0$: 反方向更新。

最终结果阶段

Final Bayesian Deviation
最终贝叶斯偏离

Decision Accuracy
决策准确性

Net Payoff = Accuracy Reward – Search Cost – Error Loss
净收益

11. Study 2：AI-specific 机制拆解实验

11.1 研究目的

Study 2 直接识别两个 AI-specific 机制：

算法穷尽性错觉：影响信息获取；
模糊性压缩：影响信息处理。

核心原则：

不使用低级的声明式操纵，而使用结构性线索操纵。

也就是说，不直接告诉被试“AI 搜索了很多来源”或“AI 只看了很少来源”，而是通过答案结构自然引发不同感知。

11.2 实验设计

采用 2×2 设计。

因素	水平 1	水平 2
穷尽性线索	高穷尽性	低穷尽性
模糊性压缩	高压缩 / 吸收反证	低压缩 / 悬置反证

四个条件：

1. 高穷尽性 × 高压缩
2. 高穷尽性 × 低压缩
3. 低穷尽性 × 高压缩
4. 低穷尽性 × 低压缩

所有条件保持：

最终结论一致；
证据池一致；
结论方向一致；

任务难度一致；
文本长度尽量接近。

11.3 穷尽性线索的结构性操纵

高穷尽性版本

通过跨维度整合暗示 AI 覆盖了广泛证据空间：

综合财务报表、行业景气度、供应链数据、管理层变动、宏观利率环境、同业违约模式和专家访谈信息来看，该企业未来一年进入高违约风险状态的可能性较高。

低穷尽性版本

通过单一维度分析暗示 AI 覆盖范围较窄：

根据近期财务报表中的现金流、负债率和偿债指标来看，该企业未来一年进入高违约风险状态的可能性较高。

两者最终结论相同。差异只在于：

用户感知 AI 覆盖的信息维度广度不同。

11.4 模糊性压缩的结构性操纵：吸收 vs 悬置

本文不再采用“有结论 vs 无结论”的粗糙操纵，而采用：

高压缩：提出反向证据，但解释掉；
低压缩：提出反向证据，但悬置其未解决状态。

高模糊性压缩：Explain-away / Subsume

综合来看，该企业违约风险偏高。虽然企业近期获得了一笔新融资，但该融资主要属于高息短期过桥资金，反而说明企业正面临较大的流动性压力。结合现金流恶化、短期债务集中到期和收入波动，这一融资信号并未削弱高违约风险判断，而是进一步支持企业财务压力上升的解释。

低模糊性压缩：Suspend

综合来看，该企业违约风险偏高，但这一判断建立在存在明显证据拉扯的基础上。现金流恶化和短期债务集中到期支持高风险判断；近期融资成功则构成反向约束。当前模型更重视现金流恶化信号，但融资稳定性的含义尚未完全明确。如果后续信息表明该融资具有长期稳定性，违约风险判断可能需要下调。

两者都给出同一主导性结论：

违约风险偏高。

区别在于：

高压缩版本将反证吸收到主叙事中；
低压缩版本保留反证作为尚未完全解决的冲突。

11.5 Study 2 测量

机制变量

算法穷尽性错觉
感知信息覆盖广度
继续搜寻的感知 VOI
感知证据充分性
感知证据冲突
模糊性压缩感知
反向信号感知诊断性
自治性认知闭合

行为变量

自愿抽样数量
愿意为额外证据支付的代币
是否查看反方证据
logit updating deviation
shock 隐含权重 w_i
最终净收益

11.6 预期结果

高穷尽性线索 → 更强算法穷尽性错觉 → 更低 perceived V0I → 更少抽样。

高模糊性压缩 → 更强自治性认知闭合 → 更低反向信号诊断性感知 → 更弱 log-odds updating。

高穷尽性 × 高模糊性压缩 → 最大双重贝叶斯偏离和最低净收益。

12. Study 3：治理机制与净收益实验

12.1 研究目的

Study 3 检验不同治理机制是否能够降低双重贝叶斯偏离，并评估这些机制是否具有现实可行性。

核心问题不是：

哪个机制最能增加验证？

而是：

哪个机制能在提高判断质量的同时不过度增加成本、不导致用户流失，并最终提高净收益？

12.2 实验条件

条件	描述
Baseline AI answer-first	默认 AI 直接给综合答案
Conflict-first AI	AI 先呈现关键冲突，再给结论
Uncertainty-calibrated AI	AI 给出概率范围、证据限制和不确定性提示
Source-before-answer	用户必须先查看一定证据，再看 AI 答案
Optional paid verification	用户可付费验证，正确判断有更高奖励
Mandatory verification	用户必须查看若干证据后才能决策

12.3 损失函数与净收益

设置真实代币激励：

每查看一条证据扣除一定代币；
最终判断越准确，获得奖励越高；
错误决策扣除代币；
最终代币兑换真实报酬。

核心公式：

$$\text{Net Payoff} = \text{Accuracy Reward} - \text{Search Cost} - \text{Error Loss}$$

中文：

净收益 = 准确性收益 - 搜寻成本 - 错误损失

为了提高外部效度，Study 3 不只设置一种成本结构，而是操纵不同决策环境。

环境	验证成本	错误成本	对应现实场景
低风险环境	高	低	日常信息搜索
中风险环境	中	中	组织管理判断
高风险环境	低	高	金融、医疗、安全
时间压力环境	高时间成本	高错误成本	危机决策

这样可以检验：

轻量治理在哪些情境中有效？
强制验证在哪些高风险情境中值得？
用户是否会因为治理摩擦而弃用系统？

12.5 用户选择与留存

最后一轮任务中，让用户自由选择系统：

1. 直接答案系统
2. 冲突优先系统
3. 不确定性校准系统
4. Source-before-answer 系统
5. Mandatory verification 系统

测量：

系统选择
继续使用意愿
实际净收益
主观负担
任务完成时间
用户流失率

这可以回应现实部署问题：

一种治理机制如果提高准确性但导致用户大量流失，它的现实治理价值有限。

13. Empirical Strategy

13.1 信息获取偏差识别

主要模型：

$$Nactual_i = \beta_0 + \beta_1 AIAnswerFirst_i + \beta_2 HumanExpert_i + \beta_3 AIAnswerLast_i + \beta_4 Controls_i + \epsilon_i$$

中介模型：

AI Answer-first → Algorithmic Exhaustiveness → Perceived VOI → Nactual

核心检验：

AI answer-first 是否通过算法穷尽性错觉降低自愿抽样数量？

13.2 信息处理偏差识别

主指标：

$$Updating_Deviation_i = | [\logit(Pfinal_i) - \logit(Pinterim_i)] - \log(LRshock) |$$

模型：

```
UpdatingDeviation_i  
=  $\beta_0 + \beta_1 \text{AIAAnswerFirst}_i + \beta_2 \text{HumanExpert}_i + \beta_3 \text{SearchOnly}_i$   
+  $\beta_4 \text{logit(Pinterim}_i) + \beta_5 \text{Controls}_i + \epsilon_i$ 
```

在 Study 1b 中加入 Yoked 控制后：

```
UpdatingDeviation_i  
=  $\beta_0 + \beta_1 \text{AIAAnswerFirst}_i + \beta_2 \text{YokedSearch}_i$   
+  $\beta_3 \text{InformationSetSize}_i + \beta_4 \text{Controls}_i + \epsilon_i$ 
```

关键比较：

AI answer-first vs. Search-only yoked

如果 AI 组仍然更新不足，则说明：

processing bias 不能完全由信息集大小差异解释。

13.3 隐含权重估计

计算：

```
 $w_i = [\text{logit(Pfinal}_i) - \text{logit(Pinterim}_i)] / \log(\text{LRshock})$ 
```

模型：

```
 $w_i = \beta_0 + \beta_1 \text{AIAAnswerFirst}_i + \beta_2 \text{AmbiguityCompression}_i + \beta_3 \text{Controls}_i + \epsilon_i$ 
```

预期：

AI answer-first 和 high ambiguity compression 条件下 w_i 更低。

13.4 Belief vs Preference 的区分

为避免将信念效应与偏好效应混淆，本文同时测量：

主观概率报告
信息购买行为
最终选择
风险偏好
模糊厌恶
信心校准
净收益

如果 AI 主要改变风险偏好，概率报告、信息购买和 logit 更新不一定呈现一致变化。
如果 AI 改变信念更新，则这些指标应共同表现出系统性偏离。

13.5 Double Counting 的处理

本文明确将 AI summary 建模为：

对底层证据环境的有损压缩

而不是：

独立的新证据源

因此，规范贝叶斯模型不会把 AI 总结简单当作独立信号加入。AI 总结只是底层证据池的压缩呈现。继续抽样的价值来自于恢复 AI 压缩过程中丢失的：

局部方差
反向证据
证据异质性
替代解释
权重拉扯

理论表述：

生成式 AI 综合不应被建模为独立证据，而应被建模为对证据环境的有损压缩。由于压缩过程可能降低局部方差和冲突证据的显著性，当恢复被省略方差的期望价值高于边际搜寻成本时，理性的贝叶斯决策者仍应继续抽样。

14. Variables and Measures

14.1 Independent Variables

AI answer-first synthesis
Human expert answer-first synthesis
Search-only free
Search-only yoked
AI answer-last
High vs. low exhaustiveness cue
High vs. low ambiguity compression
Conflict-first design
Uncertainty-calibrated design
Source-before-answer
Mandatory verification

14.2 Mediators

算法穷尽性错觉
感知信息覆盖广度
继续搜寻的感知 VOI
感知证据充分性
模糊性压缩
感知证据冲突
反向信号感知诊断性
自洽性认知闭合

14.3 Evidence Acquisition Outcomes

自愿抽样数量
停止搜寻点
搜寻成本
抽样偏离度
与最优抽样数量 N^* 的差距

14.4 Evidence Processing Outcomes

$\text{logit}(P_{\text{final}}) - \text{logit}(P_{\text{interim}})$
logit updating deviation

隐含 shock 权重 w_i
反向信号后的信念修正

14.5 Decision Outcomes

最终后验概率
最终选择
判断准确性
净收益
系统选择
继续使用意愿
用户流失率

15. Expected Contributions

15.1 从 AI anchoring 到 dual Bayesian distortion

本文不再将 AI 的影响简化为锚定效应，而是提出 AI 可能造成两类不同的贝叶斯偏离：

信息获取阶段的抽样不足；
信息处理阶段的对数几率更新不足。

这使论文从传统心理偏差研究升级到规范性信念更新研究。

15.2 从 advice-taking 到 algorithmic sensemaking

本文不把 AI 视为普通建议来源，而是视为意义建构代理。

AI 的作用不是简单地说：

我建议你选 A。

而是先替用户组织世界：

哪些证据重要；
哪些冲突可以被吸收；

哪些结论最合理；
是否还有必要继续搜索。

这拓展了 AI advice-taking 研究。

15.3 提出算法穷尽性错觉作为 AI-specific 机制

本文指出 AI 与人类专家的关键区别之一在于，用户可能认为 AI 覆盖了更大的信息空间。

这种算法穷尽性错觉会降低继续搜寻的感知信息价值，从而提前触发搜索停止规则。

15.4 提出模糊性压缩作为信息处理机制

本文指出 AI 不只是给答案，而是通过解释、吸收和重构冲突证据，将复杂证据环境压缩为连贯叙事。

这种模糊性压缩会降低反向证据的感知诊断性，使用户在后续面对高 LR shock 时表现出 log-odds updating attenuation。

15.5 将 AI 治理转化为净收益问题

本文不简单主张“更多验证更好”，而是用净收益框架评估治理机制。

核心观点是：

最优治理不是最大化验证；
最优治理是在准确性收益、搜寻成本、错误损失和用户留存之间取得平衡。

16. Anticipated Critiques and Responses

质疑一：这是不是 confirmation bias 旧酒装新瓶？

回应：

本文承认证实性偏见可能存在，但本文的贡献在于识别 AI-specific 的前置条件。通过比较 AI answer-first、人类专家 answer-first、search-only free 和 search-only yoked 条件，本文可以区分：

一般结构化总结效应
vs.

如果人类专家同样连贯的报告产生相同效果，则说明机制主要是 structured synthesis。

如果 AI 条件更强，并且差异由算法穷尽性错觉解释，则说明存在 AI-specific 成分。

质疑二：AI 组更新小是否只是概率边界效应？

回应：

本文不使用概率绝对差作为主指标，而使用 log-odds 更新。

核心指标为：

$$\text{Updating Deviation} = | [\text{logit}(P_{\text{final}}) - \text{logit}(P_{\text{interim}})] - \log(\text{LR}_{\text{shock}}) |$$

在 log-odds 尺度下，贝叶斯更新是线性的，可以避免概率边界造成的天花板效应。

质疑三：AI 组更新不足是否只是因为第一阶段看得少？

回应：

Study 1b 使用 Search-only yoked control，确保 AI 组和 yoked 组在进入外生冲击前拥有相同数量的证据。

如果在信息集大小相同的情况下，AI 组仍然表现出更弱的 log-odds updating，则说明处理偏差不能完全由阅读量差异解释。

质疑四：如果 AI explain-away 是正确的，用户降低反向证据权重不是理性的吗？

回应：

因此，本文并不声称所有 explain-away 都是错误的；本文检验的是：

在客观高诊断性反向信号存在时，AI 的连贯叙事是否导致用户低估该信号的规范证据权重。

质疑五：代币激励是否足以对冲认知懒惰？

回应：

本文不假设代币激励能够完全消除认知懒惰。相反，认知努力成本正是理论的一部分。Study 3 将操纵不同激励强度和成本结构，以检验 AI 效应是否在高激励环境中仍然存在。

可以设置：

低激励
中激励
高激励

如果 AI 效应在高激励条件下仍存在，则说明其不只是低激励下的敷衍行为。

质疑六：离散抽样是否牺牲生态效度？

回应：

离散抽样是为了获得可计算的贝叶斯基准。完全自然的长文搜索环境虽然生态效度更高，但难以确定每个信号的 LR 和规范后验。

本文采取双层策略：

主实验：离散信号抽样，确保内部效度和规范基准；
补充实验：长文证据包或模拟网页环境，检验外部效度。

17. Limitations

第一，实验中的证据池虽然被试看似开放，但仍是研究者构造的模拟环境。它不能完全复现真实搜索中的复杂网页、长文、视频和社交信息流。

第二，本文的贝叶斯基准依赖于研究者设定的似然比和证据生成结构。虽然这有助于识别规范偏离，但也意味着研究结论需要在其他场景中进一步验证。

第三，AI-specific 机制与一般信任、认知懒惰、权威服从之间可能存在相关性。本文将通过控制变量、中介模型和对照组减少混淆，但无法一次性穷尽所有心理机制。

第四，实验代币激励无法完全等同现实世界高风险决策中的巨额收益和损失。Study 3 通过操纵成本结构缓解这一问题，但外部效度仍需要后续现场实验或真实平台数据进一步验证。

第五，在现实世界中，AI 对反向证据的 explain-away 有时可能是高质量推理。本文只检验在客观 LR 已知的实验环境中，AI 叙事是否导致用户低估高诊断性反向信号。

18. Governance Implications

本文的治理启示不是简单地要求用户“多验证”，而是根据不同风险环境设计不同的信息架构。

低风险环境

例如日常信息搜索、低成本消费决策。

适合：

轻量级 uncertainty reminder
可选来源展开
低摩擦 verification prompt

不适合：

强制验证
source-before-answer

因为成本可能超过收益。

中风险环境

例如组织管理判断、一般投资分析。

适合：

conflict-first AI
uncertainty-calibrated AI
source-traceable summary

目标是降低模糊性压缩和过度认知闭合，同时保持可用性。

高风险环境

适合：

source-before-answer
mandatory verification

confidence calibration
required exposure to disconfirming evidence

在高错误成本环境下，强治理机制的净收益可能为正。

核心治理原则

1. 不应只优化答案流畅性；
2. 不应让 AI 过度压缩证据冲突；
3. 高风险系统应显式呈现关键反向证据；
4. 来源透明不够，还需要冲突透明；
5. 最优治理不是最大化验证，而是最大化净收益；
6. AI 系统应评估其对用户搜索停止规则和更新权重的影响。

19. Expected Findings

本文预期发现：

第一，AI answer-first 会降低用户继续抽样的意愿，特别是在用户形成较强算法穷尽性错觉时。

第二，AI answer-first 会使用户更早停止搜寻，其自愿抽样数量可能低于规范最优抽样量。

第三，在使用 log-odds 更新指标后，AI answer-first 组仍可能表现出对高诊断性反向信号的权重折现。

第四，在 Yoked control 中，即使控制信息集大小，AI answer-first 组仍可能表现出更强 updating deviation，说明 AI 叙事影响的不只是信息获取，也包括信息处理。

第五，AI 的负面影响并非在所有情境中都出现。在低风险、低错误成本任务中，AI 可能提高效率；但在高风险、高错误成本任务中，AI 引发的抽样不足和更新不足更可能造成净收益损失。

第六，治理机制的有效性取决于成本结构。Conflict-first 和 uncertainty-calibrated 设计可能在较低用户负担下改善信念更新；mandatory verification 可能在高风险场景下更有价值，但在低风险场景中可能因成本过高而降低净收益和用户留存。

新建 文本文档